

# Modelos Lineares Generalizados

Disciplina ofertada pelo DECAT/UFS

Código: ESTAT0092

Nível: Graduação

Carga horária: 60h

Período: 2020.2

Professor responsável e ministrante: Luiz Henrique Dore

## Aulas 5 e 6: notas complementares

# 1 Derivada de primeira ordem da log-verossimilhança com relação a $\beta$

Conforme visto no tópico 10, a função de log-verossimilhança é dada por

$$l(\beta, \phi) = \phi^{-1} \left( \sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n c(Y_i, \phi), \quad (1)$$

onde  $\beta = (\beta_0, \beta_1, \dots, \beta_p)$ . Vamos calcular  $\frac{\partial l}{\partial \beta_j}$ , a derivada de  $l(\beta, \phi)$  com relação ao  $j$ -ésimo componente de  $\beta$ . Note que  $b'(\theta_i) = \mu_i = g^{-1}(\eta_i) = g^{-1}(\mathbf{x}_i^T \beta)$ . Logo,  $\theta_i$  pode ser visto como a seguinte composição de funções:  $\theta_i \equiv \theta_i(\mu_i(\eta_i(\beta_i)))$  [1, p. 71]. Pela regra da cadeia,

$$\frac{\partial \theta_i}{\partial \beta_j} = \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_j}.$$

Utilizando esse resultado e, novamente, a regra da cadeia, tem-se que

$$\frac{\partial l}{\partial \beta_j} = \frac{\partial l}{\partial \theta_i} \frac{\partial \theta_i}{\partial \beta_j} = \frac{\partial l}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_j}.$$

Portanto,

$$\frac{\partial l}{\partial \beta_j} = \phi^{-1} \sum_{i=1}^n Y_i \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_j} - \phi^{-1} \sum_{i=1}^n \frac{\partial b(\theta_i)}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_j}.$$

Note que

$$\frac{\partial \theta_i}{\partial \mu_i} = \frac{1}{\frac{\partial \mu_i}{\partial \theta_i}} = \frac{1}{V(\mu_i)} = V_i^{-1},$$

onde  $V_i = V(\mu_i)$  é a função de variância (ver tópico 4). Além disso,

$$\frac{\partial b(\theta_i)}{\partial \theta_i} = b'(\theta_i) = \mu_i \quad \text{e} \quad \frac{\partial \eta_i}{\partial \beta_j} = x_{ij}.$$

Logo, a derivada de  $l(\beta, \phi)$ , com relação a  $\beta_j$ , é dada por [2, p. 21]

$$\begin{aligned} \frac{\partial l}{\partial \beta_j} &= \phi^{-1} \sum_{i=1}^n Y_i V_i^{-1} \frac{\partial \mu_i}{\partial \eta_i} x_{ij} - \phi^{-1} \sum_{i=1}^n \mu_i V_i^{-1} \frac{\partial \mu_i}{\partial \eta_i} x_{ij} = \\ &= \sum_{i=1}^n \phi^{-1} \sqrt{\frac{\omega_i}{V_i}} (y_i - \mu_i) x_{ij}, \end{aligned} \quad (2)$$

onde  $\omega_i = (\partial \mu_i / \partial \eta_i)^2 / V_i$ .

# 2 Derivada de primeira ordem da log-verossimilhança com relação a $\phi$

Derivando a log-verossimilhança (1), com relação a  $\phi$ , obtém-se [1, p. 114]

$$\frac{\partial l}{\partial \phi} = -\phi^{-2} \left( \sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n \frac{\partial c(Y_i, \phi)}{\partial \phi}. \quad (3)$$

### 3 Derivadas de segunda ordem da log-verossimilhança com relação a $\beta$

Conforme visto na seção 1, a derivada de  $l(\beta, \phi)$ , com relação a  $\beta_j$ , pode ser escrita como

$$\frac{\partial l}{\partial \beta_j} = \phi^{-1} \sum_{i=1}^n Y_i \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ij} - \phi^{-1} \sum_{i=1}^n \mu_i \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ij}$$

Logo, a derivada parcial de  $l(\beta, \phi)$ , com relação a  $\beta_j$  e  $\beta_l$ , é

$$\begin{aligned} \frac{\partial^2 l}{\partial \beta_j \partial \beta_l} &= \frac{\partial}{\partial \beta_l} \left( \frac{\partial l}{\partial \beta_j} \right) = \phi^{-1} \sum_{i=1}^n Y_i \frac{\partial}{\partial \beta_l} \left( \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \right) x_{ij} - \phi^{-1} \sum_{i=1}^n \frac{\partial}{\partial \beta_l} \left( \mu_i \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \right) x_{ij} = \\ &= \phi^{-1} \sum_{i=1}^n Y_i \left[ \frac{\partial^2 \theta_i}{\partial \mu_i \partial \beta_l} \frac{\partial \mu_i}{\partial \eta_i} + \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial^2 \mu_i}{\partial \eta_i \partial \beta_l} \right] x_{ij} - \\ &- \phi^{-1} \sum_{i=1}^n \left[ \frac{\partial \mu_i}{\partial \beta_l} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} + \mu_i \frac{\partial^2 \theta_i}{\partial \mu_i \partial \beta_l} \frac{\partial \mu_i}{\partial \eta_i} + \mu_i \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial^2 \mu_i}{\partial \eta_i \partial \beta_l} \right] x_{ij}. \end{aligned} \quad (4)$$

Aplicando a regra da cadeia, pode-se escrever

$$\begin{aligned} \frac{\partial^2 \theta_i}{\partial \mu_i \partial \beta_l} &= \frac{\partial}{\partial \beta_l} \left( \frac{\partial \theta_i}{\partial \mu_i} \right) = \frac{\partial}{\partial \mu_i} \left( \frac{\partial \theta_i}{\partial \mu_i} \right) \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_l} = \frac{\partial^2 \theta_i}{\partial \mu_i^2} \frac{\partial \mu_i}{\partial \eta_i} x_{il}, \\ \frac{\partial^2 \mu_i}{\partial \eta_i \partial \beta_l} &= \frac{\partial}{\partial \beta_l} \left( \frac{\partial \mu_i}{\partial \eta_i} \right) = \frac{\partial}{\partial \eta_i} \left( \frac{\partial \mu_i}{\partial \eta_i} \right) \frac{\partial \eta_i}{\partial \beta_l} = \frac{\partial^2 \mu_i}{\partial \eta_i^2} x_{il} \quad \text{e} \\ \frac{\partial \mu_i}{\partial \beta_l} &= \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_l} = \frac{\partial \mu_i}{\partial \eta_i} x_{il}. \end{aligned}$$

Substituindo essas expressões em (4), obtém-se [2, p. 21]

$$\begin{aligned} \frac{\partial^2 l}{\partial \beta_j \partial \beta_l} &= \phi^{-1} \sum_{i=1}^n Y_i \left[ \frac{\partial^2 \theta_i}{\partial \mu_i^2} \left( \frac{\partial \mu_i}{\partial \eta_i} \right)^2 x_{il} + \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial^2 \mu_i}{\partial \eta_i^2} x_{il} \right] x_{ij} - \\ &- \phi^{-1} \sum_{i=1}^n \left[ \left( \frac{\partial \mu_i}{\partial \eta_i} \right)^2 \frac{\partial \theta_i}{\partial \mu_i} x_{il} + \mu_i \frac{\partial^2 \theta_i}{\partial \mu_i^2} \left( \frac{\partial \mu_i}{\partial \eta_i} \right)^2 x_{il} + \mu_i \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial^2 \mu_i}{\partial \eta_i^2} x_{il} \right] x_{ij} = \\ &= \phi^{-1} \sum_{i=1}^n (Y_i - \mu_i) \frac{\partial^2 \theta_i}{\partial \mu_i^2} \left( \frac{\partial \mu_i}{\partial \eta_i} \right)^2 x_{ij} x_{il} + \\ &+ \phi^{-1} \sum_{i=1}^n (Y_i - \mu_i) \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial^2 \mu_i}{\partial \eta_i^2} x_{ij} x_{il} - \phi^{-1} \sum_{i=1}^n \left( \frac{\partial \mu_i}{\partial \eta_i} \right)^2 \frac{\partial \theta_i}{\partial \mu_i} x_{ij} x_{il}. \end{aligned} \quad (5)$$

### 4 Derivadas de segunda ordem da log-verossimilhança com relação a $\beta$ e a $\phi$

Derivando (2) com relação a  $\phi$ , obtém-se [1, p. 114]

$$\frac{\partial^2 l}{\partial \beta_j \partial \phi} = -\phi^{-2} \sum_{i=1}^n \sqrt{\frac{\omega_i}{V_i}} (Y_i - \mu_i) x_{ij} \quad (6)$$

## 5 Derivadas de segunda ordem da log-verossimilhança com relação a $\phi$

Derivando (3) com relação a  $\phi$ , obtém-se

$$\frac{\partial^2 l}{\partial \phi^2} = 2\phi^{-3} \left( \sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n \frac{\partial^2 c(Y_i, \phi)}{\partial \phi^2}. \quad (7)$$

## 6 Valor esperado das derivadas de segunda ordem da log-verossimilhança

Utilizando a fórmula (5), o valor esperado de  $\frac{\partial^2 l}{\partial \beta_j \partial \beta_l}$  fica dado por

$$\begin{aligned} E \left[ \frac{\partial^2 l}{\partial \beta_j \partial \beta_l} \right] &= \phi^{-1} \sum_{i=1}^n E(Y_i - \mu_i) \frac{\partial^2 \theta_i}{\partial \mu_i^2} \left( \frac{\partial \mu_i}{\partial \eta_i} \right)^2 x_{ij} x_{il} + \\ &+ \phi^{-1} \sum_{i=1}^n E(Y_i - \mu_i) \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial^2 \mu_i}{\partial \eta_i^2} x_{ij} x_{il} - \phi^{-1} \sum_{i=1}^n \left( \frac{\partial \mu_i}{\partial \eta_i} \right)^2 \frac{\partial \theta_i}{\partial \mu_i} x_{ij} x_{il} \\ &= -\phi^{-1} \sum_{i=1}^n \left( \frac{\partial \mu_i}{\partial \eta_i} \right)^2 \frac{\partial \theta_i}{\partial \mu_i} x_{ij} x_{il} = -\phi^{-1} \sum_{i=1}^n \omega_i x_{ij} x_{il}. \end{aligned} \quad (8)$$

Utilizando a fórmula (6), o valor esperado de  $\frac{\partial^2 l}{\partial \beta_j \partial \phi}$  fica dado por

$$E \left[ \frac{\partial^2 l}{\partial \beta_j \partial \phi} \right] = -\phi^{-2} \sum_{i=1}^n \left( \sqrt{\frac{\omega_i}{V_i}} E(Y_i - \mu_i) x_{ij} \right) = 0. \quad (9)$$

Utilizando a fórmula (7), o valor esperado de  $\frac{\partial^2 l}{\partial \phi^2}$  fica dado por

$$E \left[ \frac{\partial^2 l}{\partial \phi^2} \right] = 2\phi^{-3} \left( \sum_{i=1}^n E(Y_i) \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n E \left( \frac{\partial^2 c(Y_i, \phi)}{\partial \phi^2} \right) = \quad (10)$$

$$= 2\phi^{-3} \left( \sum_{i=1}^n \mu_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n E \left( \frac{\partial^2 c(Y_i, \phi)}{\partial \phi^2} \right) \quad (11)$$

## 7 Valor esperado de $U_\phi$

Conforme visto no t3pico 11,  $U_\phi$  3 a derivada da fun33o de log-verossimilhan3a com rela33o ao parâmetro  $\phi$ . No t3pico 10, viu-se que a fun33o de log-verossimilhan3a 3 dada por

$$l(\beta, \phi) = \ln [L(\beta, \phi)] = \ln \left[ \prod_{i=1}^n f(Y_i; \theta_i, \phi) \right] = \sum_{i=1}^n \ln [f(Y_i; \theta_i, \phi)].$$

Dessa forma,  $U_\phi$  pode ser escrita como

$$U_\phi = \frac{\partial l}{\partial \phi} = \sum_{i=1}^n \frac{\partial \ln [f(Y_i; \theta_i, \phi)]}{\partial \phi} = \sum_{i=1}^n \frac{\partial f(Y_i; \theta_i, \phi) / \partial \phi}{f(Y_i; \theta_i, \phi)} = \sum_{i=1}^n U_{i,\phi},$$

onde  $U_{i,\phi} = \frac{\partial f(Y_i; \theta_i, \phi) / \partial \phi}{f(Y_i; \theta_i, \phi)}$ . Segue-se que

$$E[U_\phi] = \sum_{i=1}^n E[U_{i,\phi}]. \quad (12)$$

Agora,

$$E[U_{i,\phi}] = \int_{-\infty}^{\infty} U_{i,\phi} f(y_i; \theta_i, \phi) dy_i = \int_{-\infty}^{\infty} \frac{\partial f(y_i; \theta_i, \phi) / \partial \phi}{f(y_i; \theta_i, \phi)} \cdot f(y_i; \theta_i, \phi) dy_i = \int_{-\infty}^{\infty} \frac{\partial f(y_i; \theta_i, \phi)}{\partial \phi} dy_i.$$

Conforme mencionado no t3pico 2, sup3e-se que a fam3lia exponencial satisfaz algumas condi33es de regularidade. Uma dessas condi33es diz que o suporte da fam3lia exponencial n3o depende dos parâmetros. Essa condi33o garante que, quando aplicadas a  $f(y_i; \theta, \phi)$ , as opera33es de diferencia33o com rela33o aos parâmetros e integra33o com rela33o a  $y_i$  s3o permut3veis. Isso significa que a 3ltima integral acima pode ser expressa como

$$\int_{-\infty}^{\infty} \frac{\partial f(y_i; \theta_i, \phi)}{\partial \phi} dy_i = \frac{\partial}{\partial \phi} \left( \int_{-\infty}^{\infty} f(y_i; \theta_i, \phi) dy_i \right).$$

Mas  $\int_{-\infty}^{\infty} f(y_i; \theta_i, \phi) dy_i = 1$  3 constante, pois  $f(y_i; \theta_i, \phi)$  3 uma fun33o de densidade de probabilidade. Como a derivada de uma fun33o constante 3 zero, segue-se que

$$E[U_{i,\phi}] = \int_{-\infty}^{\infty} \frac{\partial f(y_i; \theta_i, \phi)}{\partial \phi} dy_i = \frac{\partial}{\partial \phi} \left( \int_{-\infty}^{\infty} f(y_i; \theta_i, \phi) dy_i \right) = 0.$$

Substituindo em (12), obt3m-se

$$E[U_\phi] = \sum_{i=1}^n E[U_{i,\phi}] = 0.$$

## Refer3ncias

- [1] G. M. Cordeiro e C. G. B. Dem3trio, *Modelos lineares generalizados e extens3es*, 2013, dispon3vel em <https://docs.ufpr.br/~taconeli/CE22518/LivClarice.pdf>.
- [2] G. A. Paula, *Modelos lineares generalizados com apoio computacional*, 2013, dispon3vel em [https://www.ime.usp.br/~giapaula/texto\\_2013.pdf](https://www.ime.usp.br/~giapaula/texto_2013.pdf).