

## **Modelos lineares generalizados**

**Disciplina ofertada pelo DECAT/UFS**

Código: ESTAT0092

Nível: Graduação

Carga horária: 60h

Período: 2020.2

Professor responsável e ministrante: Luiz Henrique Dore

**Aula 3: Formulação de um MLG, função de ligação canônica e casos particulares**

# Sumário

- 1 Informações sobre a aula
  - Metas
  - Objetivos
  - Pré-requisitos
- 2 Introdução
- 3 Aula 3
  - Tópico 4: formulação de um MLG
  - Tópico 5: função de ligação canônica
  - Tópico 6: outros casos particulares
- 4 Referências

# Metas

- 1 Introduzir o modelo linear generalizado, apresentando a sua formulação em termos dos componentes aleatório e sistemático e da função de ligação.
- 2 Apresentar a definição de função de ligação canônica.

# Objetivos

- Após estudar essa aula, o aluno ou aluna será capaz de:
  - 1 formular o modelo linear generalizado, através da especificação dos componentes aleatório e sistemático e da função de ligação;
  - 2 entender o papel de cada um desses componentes no modelo;
  - 3 identificar a ligação canônica de uma dada distribuição.

# Pré-requisitos

1 Aula 2.

# Introdução

- Na aula 2, discutiu-se sobre a importância de se estudar a associação entre duas ou mais variáveis.
- Em geral, pode-se dizer que duas variáveis são associadas, ou relacionadas, quando uma variação sistemática em uma delas é acompanhada por uma variação sistemática na outra.
- O conhecimento da existência de uma associação entre duas ou mais variáveis encontra várias aplicações na prática, tais como prever, explicar e/ou controlar o valor de uma das variáveis a partir dos valores das demais.
- A modelagem de regressão consiste na aplicação de métodos estatísticos para 1) verificar a existência de associação entre duas ou mais variáveis e 2) usar essa associação para representar uma das variáveis, denominada **variável resposta**, como função das demais, denominadas **variáveis preditoras**.

# Introdução

- A representação da variável resposta como uma função das variáveis preditoras é feita por modelos matemáticos conhecidos como **modelos de regressão**.
- A modelagem de regressão é mais comumente utilizada quando se deseja obter o valor **desconhecido** de uma variável resposta a partir dos valores **conhecidos** das variáveis preditoras.
- Um modelo de regressão é composto por equações, as quais descrevem a relação funcional entre a resposta e as variáveis preditoras, e, possivelmente, um conjunto de suposições sobre os termos dessas equações.
- Um modelo de regressão pode ser formulado especificando-se três componentes: 1) uma distribuição de probabilidade para a resposta; 2) uma função  $\eta$ , linear nas preditoras e 3) uma relação funcional entre a média da resposta e  $\eta$ .

# Introdução

- Essa formulação comporta, por exemplo, os modelos linear normal, de Poisson e logístico.
- O modelo linear generalizado é formulado dessa mesma maneira.
- Uma das principais características do modelo linear generalizado é que a distribuição de probabilidade da variável resposta pode ser qualquer membro da família exponencial.
- Na presente aula, é apresentada uma formulação para o modelo linear generalizado.
- O papel de cada um dos três componentes que formam o modelo é discutido.
- Por fim, são apresentados alguns casos particulares.



## Tópico 4: formulação de um MLG

- Seja  $Y$  a variável resposta e sejam  $x_1, \dots, x_p$  os valores das variáveis preditoras.
- O **modelo linear generalizado** (MLG) assume que  $Y$  é uma variável aleatória tal que
  - 1 a distribuição de  $Y$  pertence à família exponencial;
  - 2  $\eta(x_1, \dots, x_p; \beta_0, \dots, \beta_p) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$ ,
  - 3  $g(\mu) = \eta(x_1, \dots, x_p; \beta_0, \dots, \beta_p)$ ;onde  $\mu$  é a média de  $Y$  e  $g$  é uma função monótona diferenciável.
- Modelos como o modelo linear normal, de Poisson e logístico especificam uma distribuição de probabilidade para  $Y$  e uma relação funcional entre  $\mu$  e  $\eta$ .
- O MLG, proposto por Nelder e Wedderburn [2], estende esses três modelos, e vários outros, de duas formas.

## Tópico 4: formulação de um MLG

- Por um lado, a distribuição da variável resposta deixa de ser uma distribuição específica e passa a ser qualquer membro da família exponencial.
- Por outro, a transformação aplicada à média também deixa de ser uma transformação específica e passa a ser qualquer função monótona e diferenciável  $g$ .
- Essas duas generalizações tornam bastante flexíveis os MLGs.
- Além da flexibilidade, os MLGs permitem que teorias e métodos, envolvidos nos processos de estimação, inferência e diagnóstico para diversos modelos de regressão, sejam desenvolvidos de forma unificada.
- Ou seja, em geral, as técnicas desenvolvidas para um MLG servem para todos os seus submodelos.

## Tópico 4: formulação de um MLG

- Os três componentes do modelo são denominados **componente aleatório**, **componente sistemático** e **função de ligação**.
- O componente aleatório é a resposta  $Y$  e sua distribuição de probabilidade.
- A distribuição de  $Y$  deve pertencer à família exponencial.
- Isto é, a função de densidade de probabilidade de  $Y$  pode ser escrita como

$$f(y; \theta, \phi) = \exp \{ \phi^{-1} [\theta y - b(\theta)] + c(y, \phi) \},$$

onde  $\theta$  e  $\phi$  são parâmetros e  $b(\cdot)$  e  $c(\cdot, \cdot)$  são funções conhecidas.

- O parâmetro  $\theta$  é chamado parâmetro canônico e  $\phi$  é o parâmetro de dispersão.

## Tópico 4: formulação de um MLG

- Conforme visto na aula 2, a média e a variância de  $Y$  são

$$\mu = E(Y) = b'(\theta) \quad \text{e} \quad \text{Var}(Y) = \phi b''(\theta).$$

- Note que

$$b''(\theta) = \frac{\partial b'(\theta)}{\partial \theta} = \frac{\partial \mu}{\partial \theta}.$$

- Escrevendo,  $\frac{\partial \mu}{\partial \theta}$  como uma função  $V(\mu)$  de  $\mu$ , obtém-se

$$\text{Var}(Y) = \phi V(\mu).$$

- A função  $V(\mu)$  é denominada **função de variância**.
- A função de variância pode ser constante ou pode, de fato, depender de  $\mu$ .

## Tópico 4: formulação de um MLG

- Quando  $V(\mu)$  é constante, a variância de  $Y$  também é. Nesse caso, a variável resposta é homoscedástica.
- Se  $V(\mu)$  depende de  $\mu$ , a resposta pode ser heteroscedástica, pois, de acordo com o modelo,  $\mu$  pode variar com as preditoras.
- Portanto, o MLG pode se adequar às situações nas quais se observa homoscedasticidade e àquelas nas quais se observa heteroscedasticidade.
- A escolha da distribuição de  $Y$  é, em geral, baseada na natureza da própria variável resposta  $Y$ .
- Por exemplo, se  $Y$  representa uma contagem, a distribuição de Poisson é uma escolha plausível.
- Se  $Y$  é uma variável binária, a distribuição de Bernoulli é uma escolha mais adequada.

## Tópico 4: formulação de um MLG

- O componente sistemático é a função  $\eta$ , a qual é linear nas variáveis preditoras.
- A função  $\eta$  é denominada **preditor linear**.
- O componente sistemático é especificado listando-se as variáveis preditoras que acredita-se estarem associadas à resposta.
- O MLG estabelece uma relação funcional entre a resposta e as variáveis preditoras, assumindo que há uma relação funcional entre a média da resposta e as variáveis preditoras.
- O terceiro componente, a função de ligação  $g$ , **lineariza** a relação funcional entre a média e as variáveis preditoras.
- De acordo com o MLG, a média da resposta é dada por

$$\mu = g^{-1}(\eta) = g^{-1}(\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p).$$

## Tópico 4: formulação de um MLG

- Ou seja, a função de ligação determina a forma como a média varia em termos das variáveis preditoras.
- Os valores possíveis para  $\mu$  dependem da distribuição de  $Y$ .
- Se a distribuição de  $Y$  é uma Poisson, então  $\mu > 0$ ; se é uma binomial, então  $0 < \mu < 1$ .
- Em geral, a função de ligação é escolhida de modo a garantir que  $g^{-1}(\eta)$  seja um valor possível para  $\mu$ .
- Funções de ligações comuns são a identidade  $g(\mu) = \mu$ , o logaritmo  $g(\mu) = \ln(\mu)$  a raiz quadrada  $g(\mu) = \sqrt{\mu}$  e a função logit  $g(\mu) = \ln\left(\frac{\mu}{1-\mu}\right)$ . Veja outros exemplos em [3, p. 8].
- Para mais informações sobre os componentes do MLG, veja a seção 2.3 de [1]

## Tópico 4: formulação de um MLG

### Exemplo 1

Conforme visto na aula 2, a distribuição normal pertence à família exponencial e sua função de densidade é

$$\begin{aligned} f(y; \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(y - \mu)^2}{2\sigma^2} \right\} \\ &= \exp \left\{ \phi^{-1} [y\theta - b(\theta)] + c(y, \phi) \right\}, \quad y \in \mathbb{R}, \end{aligned}$$

onde

$$\theta = \mu, \quad b(\theta) = \frac{\theta^2}{2}, \quad \phi = \sigma^2 \text{ e } c(y, \phi) = -\frac{1}{2} \frac{y^2}{\phi} - \frac{1}{2} \ln(2\pi\phi).$$

O modelo de regressão linear normal é um caso particular do MLG, no qual  $Y$  segue distribuição normal e a função de ligação é a função identidade  $g(\mu) = \mu$ .



## Tópico 4: formulação de um MLG

### Continuação do exemplo 1

Ou seja, o modelo linear normal pode ser formulado como

- ①  $Y \sim N(\mu, \sigma^2);$
- ②  $\eta(x_1, \dots, x_p; \beta_0, \dots, \beta_p) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p;$
- ③  $g(\mu) = \mu = \eta(x_1, \dots, x_p; \beta_0, \dots, \beta_p).$

Como  $\mu \equiv \mu(\theta) = \theta$ , a função de variância é

$$V(\mu) = \frac{\partial \mu}{\partial \theta} = 1 \quad \text{e} \quad \text{Var}(Y) = \phi V(\mu) = \phi.$$

Ou seja, a variância é constante. Portanto, de acordo com o modelo linear normal, a resposta é homoscedástica. Note que

$$\frac{\partial \mu}{\partial x_j} = \beta_j, \quad j \in \{1, 2, \dots, p\}.$$

## Tópico 4: formulação de um MLG

### Continuação do exemplo 1

Portanto, o coeficiente  $\beta_i$ , associado à variável  $x_j$ , é a taxa de variação de  $\mu$  com relação à  $x_j$ . Note também que

$$\beta_0 + \beta_1 x_1 + \cdots + \beta_j (x_j + 1) + \cdots + \beta_p x_p = \mu + \beta_j.$$

Isto é, de acordo com o modelo linear normal,  $\mu$  varia **aditivamente** com relação às variáveis preditoras. Se  $\beta_j > 0$ , então o aumento (redução) de uma unidade em  $x_j$  corresponde a um aumento (redução) de  $\beta_j$  unidades, em média, na variável resposta. Se  $\beta_j < 0$ , então o aumento (redução) de uma unidade em  $x_j$  corresponde a uma redução (aumento) de  $\beta_j$  unidades, em média, na variável resposta.

## Tópico 4: formulação de um MLG

### Exemplo 2

Conforme visto na aula 2, a distribuição de Poisson pertence à família exponencial e sua função de distribuição é

$$\begin{aligned} f(y; \mu, \sigma^2) &= \frac{\mu^y e^{-\mu}}{y!} = \\ &= \exp \left\{ \phi^{-1} \cdot [y\theta - b(\theta)] + c(y, \phi) \right\}, \quad y \in \{0, 1, \dots\} \end{aligned}$$

onde

$$\theta = \ln(\mu), \quad b(\theta) = e^\theta, \quad \phi = 1 \text{ e } c(y, \phi) = -\ln(y!) (2\pi\phi).$$

O modelo de regressão Poisson é o caso particular do MLG, no qual  $Y$  segue distribuição de Poisson e a função de ligação é o logaritmo  $g(\mu) = \ln(\mu)$ .

## Tópico 4: formulação de um MLG

### Continuação do exemplo 2

Ou seja, o modelo de regressão Poisson pode ser escrito como pode ser escrita como

- 1  $Y \sim \text{Poisson}(\mu);$
- 2  $\eta(x_1, \dots, x_p; \beta_0, \dots, \beta_p) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p;$
- 3  $g(\mu) = \ln(\mu) = \eta(x_1, \dots, x_p; \beta_0, \dots, \beta_p).$

Como  $\mu \equiv \mu(\theta) = e^\theta$ , a função de variância é

$$V(\mu) = \frac{\partial \mu}{\partial \theta} = e^\theta = \mu \quad \text{e} \quad \text{Var}(Y) = \phi V(\mu) = \mu.$$

Ou seja, de acordo com o modelo de regressão Poisson, a variância da resposta é igual à média. Portanto, a resposta pode ser heteroscedástica. A média da resposta é

$$\mu = e^\eta = e^{\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p} = e^{\beta_0} e^{\beta_1 x_1} \dots e^{\beta_p x_p}.$$

## Tópico 4: formulação de um MLG

### Continuação do exemplo 2

Portanto,

$$\frac{\partial \mu}{\partial x_j} = \beta_j \cdot \mu.$$

Dessa forma,  $\mu$  varia exponencialmente com relação a  $x_j$ , a uma taxa de  $\beta_j$  unidades. Note que

$$e^{\beta_0 + \beta_1 x_1 + \dots + \beta_j (x_j + 1) + \dots + \beta_p x_p} = e^{\beta_j} \mu.$$

Isto é,  $\mu$  varia **multiplicativamente** com relação às variáveis preditoras. Se  $\beta_j > 0$ , então, quando  $x_j$  aumenta (diminui) uma unidade, a resposta fica, em média,  $e^{\beta_j}$  vezes maior (menor). Se  $\beta_j < 0$ , então, quando  $x_j$  aumenta (diminui) uma unidade, a resposta fica, em média,  $e^{\beta_j}$  vezes menor (maior).

## Tópico 4: formulação de um MLG

### Exemplo 3

Conforme visto na aula 2, a distribuição de Bernoulli pertence à família exponencial e sua função de distribuição é

$$\begin{aligned} f(y; \mu) &= \mu^y (1 - \mu)^{1-y} = \\ &= \exp \{ \phi^{-1} [y\theta - b(\theta)] + c(y; \phi) \} = f(y; \theta, \phi), \quad y \in \{0, 1\}, \end{aligned}$$

onde

$$\theta = \ln \left( \frac{\mu}{1 - \mu} \right), \quad b(\theta) = \ln (1 + e^\theta), \quad \phi = 1 \text{ e } c(y; \phi) = 0.$$

O modelo de regressão logística é o caso particular do MLG, no qual  $Y$  segue distribuição de Bernoulli e a função de ligação é a função logit  $g(\mu) = \ln \left( \frac{\mu}{1 - \mu} \right)$ .

## Tópico 4: formulação de um MLG

### Continuação do exemplo 3

Ou seja, o modelo de regressão logística pode ser escrito como

- ①  $Y \sim \text{Bernoulli}(\mu)$ ;
- ②  $\eta(x_1, \dots, x_p; \beta_0, \dots, \beta_p) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$ ;
- ③  $g(\mu) = \ln\left(\frac{\mu}{1-\mu}\right) = \eta(x_1, \dots, x_p; \beta_0, \dots, \beta_p)$ .

Como  $\mu \equiv \mu(\theta) = \frac{e^\theta}{e^\theta + 1}$ , a função de variância é

$$V(\mu) = \frac{\partial \mu}{\partial \theta} = \frac{e^\theta}{(e^\theta + 1)^2} = \mu(1 - \mu) \quad \text{e} \quad \text{Var}(Y) = \phi\mu(1 - \mu).$$

Ou seja, de acordo com o modelo de regressão logística, a resposta pode ser heteroscedástica. A média da resposta é

$$\mu = \frac{e^\eta}{e^\eta + 1} = \frac{e^{\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p}}{e^{\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p} + 1}.$$

## Tópico 4: formulação de um MLG

### Continuação do exemplo 3

A interpretação dos coeficientes é feita em termos de uma quantidade denominada chance. A chance é definida como

$$\text{odds}(\mu) = \frac{\mu}{1 - \mu}$$

A chance mede a possibilidade de sucesso relativamente à possibilidade de fracasso. Se  $\text{odds}(\mu) = 2$ , então o sucesso é duas vezes mais frequente do que o fracasso. Note que

$$\frac{\partial}{\partial x_j} \text{odds}(\mu) = \beta_j \cdot \text{odds}(\mu).$$

Ou seja,  $\text{odds}(\mu)$  varia exponencialmente com relação a  $x_j$ , a uma taxa de  $\beta_j$  unidades.



## Tópico 4: formulação de um MLG

### Continuação do exemplo 3

Note também que

$$e^{\beta_0 + \beta_1 x_1 + \dots + \beta_j (x_j + 1) + \dots + \beta_p x_p} = e^{\beta_j} \cdot odds(\mu).$$

Isto é,  $odds(\mu)$  varia **multiplicativamente** com relação às preditoras. Se  $\beta_j > 0$ , então, quando  $x_j$  aumenta (diminui) uma unidade, a chance fica  $e^{\beta_j}$  vezes maior (menor). Se  $\beta_j < 0$ , então, quando  $x_j$  aumenta (diminui) uma unidade, a chance fica  $e^{\beta_j}$  vezes menor (maior).

## Tópico 5: função de ligação canônica

- A função de ligação  $g$  é dita ser uma **ligação canônica** se

$$g(\mu) \equiv g(\mu(\theta)) = \theta.$$

- Pela formulação do MLG, se  $g$  é uma ligação canônica, então

$$\theta = \eta(x_1, \dots, x_p; \beta_0, \dots, \beta_p) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p.$$

- Isto é, Pela formulação do MLG, se  $g$  é uma ligação canônica, então **o parâmetro canônico é igual ao preditor linear**.
- O uso de ligações canônicas adiciona importantes, teóricas e práticas, vantagens ao MLG, como, por exemplo, a unicidade da estimativa de máxima verossimilhança dos coeficientes, quando esta existe [3, p. 8]

## Tópico 5: função de ligação canônica

### Exemplo 4

Conforme visto na aula 2, a distribuição normal pertence à família exponencial e sua função de densidade é

$$\begin{aligned} f(y; \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(y - \mu)^2}{2\sigma^2} \right\} \\ &= \exp \left\{ \phi^{-1} [y\theta - b(\theta)] + c(y, \phi) \right\}, \quad y \in \mathbb{R}, \end{aligned}$$

onde

$$\theta = \mu, \quad b(\theta) = \frac{\theta^2}{2}, \quad \phi = \sigma^2 \text{ e } c(y, \phi) = -\frac{1}{2} \frac{y^2}{\phi} - \frac{1}{2} \ln(2\pi\phi).$$

Portanto, a função de ligação canônica da distribuição normal é a função identidade

$$g(\mu) = \mu.$$

## Tópico 5: função de ligação canônica

### Exemplo 5

Conforme visto na aula 2, a distribuição de Poisson pertence à família exponencial e sua função de distribuição é

$$\begin{aligned} f(y; \mu, \sigma^2) &= \frac{\mu^y e^{-\mu}}{y!} = \\ &= \exp \left\{ \phi^{-1} \cdot [y\theta - b(\theta)] + c(y, \phi) \right\}, \quad y \in \{0, 1, \dots\} \end{aligned}$$

onde

$$\theta = \ln(\mu), \quad b(\theta) = e^\theta, \quad \phi = 1 \text{ e } c(y, \phi) = -\ln(y!) (2\pi\phi).$$

Portanto, a função de ligação canônica da distribuição de Poisson o logaritmo

$$g(\mu) = \ln(\mu).$$

## Tópico 5: função de ligação canônica

### Exemplo 6

Conforme visto na aula 2, a distribuição de Bernoulli pertence à família exponencial e sua função de distribuição é

$$\begin{aligned} f(y; \mu) &= \mu^y (1 - \mu)^{1-y} = \\ &= \exp \{ \phi^{-1} [y\theta - b(\theta)] + c(y; \phi) \} = f(y; \theta, \phi), \quad y \in \{0, 1\}, \end{aligned}$$

onde

$$\theta = \ln \left( \frac{\mu}{1 - \mu} \right), \quad b(\theta) = \ln (1 + e^\theta), \quad \phi = 1 \text{ e } c(y; \phi) = 0.$$

Portanto, a função de ligação canônica da distribuição de Bernoulli é a função logit

$$\text{logit}(\mu) = g(\mu) = \ln \left( \frac{\mu}{1 - \mu} \right).$$

## Tópico 6: outros casos particulares

### Exemplo 7

Conforme visto na aula 2, a distribuição gama pertence à família exponencial e sua função de densidade é

$$\begin{aligned} f(y; \mu, \sigma^2) &= \frac{b^a}{\Gamma(a)} y^{a-1} e^{-by} \\ &= \exp \{ \phi^{-1} [\theta y - b(\theta)] + c(y, \phi) \}, \quad y > 0, \end{aligned}$$

onde

$$\theta = -\frac{b}{a}, \quad b(\theta) = -\ln(-\theta), \quad \phi = a^{-1}$$

e

$$c(y, \phi) = -\phi \ln(\phi) - \ln \Gamma(\phi) + (\phi - 1) \ln(y)$$

## Tópico 6: outros casos particulares

### Continuação do exemplo 7

No exemplo 14 do tópico 2, viu-se que

$$\mu \equiv \mu(\theta) = -\frac{1}{\theta}.$$

Portanto, a função de ligação canônica da distribuição gama é

$$g(\mu) = -\frac{1}{\mu}.$$

O modelo de regressão gama, com ligação canônica, pode ser formulado como

- ❶  $Y \sim \text{Gama}(a, b);$
- ❷  $\eta(x_1, \dots, x_p; \beta_0, \dots, \beta_p) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p;$
- ❸  $g(\mu) = -\frac{1}{\mu} = \eta(x_1, \dots, x_p; \beta_0, \dots, \beta_p).$

## Tópico 6: outros casos particulares

### Continuação do exemplo 7

A função de variância é

$$V(\mu) = \frac{\partial \mu}{\partial \theta} = \frac{1}{\theta^2} = \mu^2 \quad \text{e} \quad \text{Var}(Y) = \phi V(\mu) = \phi \mu^2.$$

Ou seja, o modelo de regressão, baseado na gama, supõe que a resposta pode ser heteroscedástica. Modelos de regressão gama são utilizados em situações nas quais a variável resposta assume apenas valores positivos [3, p. 114]. Note que

$$\frac{\partial g(\mu)}{\partial x_j} = \beta_j, \quad j \in \{1, 2, \dots, p\}.$$

Portanto, o coeficiente  $\beta_j$ , associado à variável  $x_j$ , é a taxa de variação de  $g(\mu) = -\frac{1}{\mu}$  com relação à  $x_j$ .



## Tópico 6: outros casos particulares

### Continuação do exemplo 7

Note também que

$$\beta_0 + \beta_1 x_1 + \cdots + \beta_j (x_j + 1) + \cdots + \beta_p x_p = \mu + \beta_j.$$

Isto é, de acordo com o modelo de regressão gama, com ligação canônica,  $-\frac{1}{\mu}$  varia **aditivamente** com relação às variáveis preditoras. Se  $\beta_j > 0$ , então o aumento (redução) de uma unidade em  $x_j$  corresponde a um aumento (redução) de  $\beta_j$  unidades em  $-\frac{1}{\mu}$ . Se  $\beta_j < 0$ , então o aumento (redução) de uma unidade em  $x_j$  corresponde a uma redução (aumento) de  $\beta_j$  unidades em  $-\frac{1}{\mu}$ .

## Tópico 6: outros casos particulares

### Exemplo 8

O modelo de regressão gama, com ligação canônica, estabelece uma relação linear entre  $-\frac{1}{\mu}$  e o preditor linear. Como o preditor linear pode assumir quaisquer valores reais, esse modelo pode atribuir valores negativos à  $\mu$ , contrariando o fato de que, no caso da distribuição gama,  $\mu > 0$ . Para contornar esse problema, pode-se utilizar, como função de ligação, o logaritmo. O modelo de regressão gama, com ligação logarítmica, pode ser formulado como

- ❶  $Y \sim \text{Gama}(a, b);$
- ❷  $\eta(x_1, \dots, x_p; \beta_0, \dots, \beta_p) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p;$
- ❸  $g(\mu) = \ln(\mu) = \eta(x_1, \dots, x_p; \beta_0, \dots, \beta_p).$

## Tópico 6: outros casos particulares

### Continuação do exemplo 8

A média da resposta é

$$\mu = e^{\eta} = e^{\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p} = e^{\beta_0} e^{\beta_1 x_1} \dots e^{\beta_p x_p}.$$

Note que  $\frac{\partial \mu}{\partial x_j} = \beta_j \cdot \mu$ . Dessa forma,  $\mu$  varia exponencialmente com relação a  $x_j$ , a uma taxa de  $\beta_j$  unidades. Agora,

$$e^{\beta_0 + \beta_1 x_1 + \dots + \beta_j (x_j + 1) + \dots + \beta_p x_p} = e^{\beta_j} \mu.$$

Isto é,  $\mu$  varia **multiplicativamente** com relação às variáveis preditoras. Se  $\beta_j > 0$ , então, quando  $x_j$  aumenta (diminui) uma unidade, a resposta fica, em média,  $e^{\beta_j}$  vezes maior (menor). Se  $\beta_j < 0$ , então, quando  $x_j$  aumenta (diminui) uma unidade, a resposta fica, em média,  $e^{\beta_j}$  vezes menor (maior).

## Tópico 6: outros casos particulares

### Exemplo 9

Conforme visto na aula 2, a distribuição binomial pertence à família exponencial e sua função de probabilidade é

$$\begin{aligned} f(y; \pi, m) &= \binom{m}{y} \pi^y (1 - \pi)^{m-y} = \\ &= \exp \{ \phi^{-1} [y\theta - b(\theta)] + c(y, \phi) \} = f(y; \theta, \phi), \end{aligned}$$

onde  $y \in \{0, 1, \dots, m\}$ ,

$$\theta = \ln \left( \frac{\pi}{1 - \pi} \right), \quad b(\theta) = m \ln (1 + e^\theta), \quad \phi = 1$$

e

$$c(y; \phi) = \ln \binom{m}{y}.$$

## Tópico 6: outros casos particulares

### Continuação do exemplo 9

No exemplo 13 da aula 2, viu-se que

$$E(Y) = \mu \equiv \mu(\theta) = m \frac{e^\theta}{e^\theta + 1} = m\pi.$$

Portanto, a ligação canônica da distribuição binomial é

$$g(\mu) = \ln \left( \frac{\mu/m}{1 - \mu/m} \right) = \ln \left( \frac{\mu}{m - \mu} \right).$$

O modelo de regressão binomial, com ligação canônica, pode ser formulado como

- ❶  $Y \sim \text{Binomial}(\pi, m);$
- ❷  $\eta(x_1, \dots, x_p; \beta_0, \dots, \beta_p) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p;$
- ❸  $g(\mu) = \ln \left( \frac{\mu}{m - \mu} \right) = \eta(x_1, \dots, x_p; \beta_0, \dots, \beta_p).$

## Tópico 6: outros casos particulares

### Continuação do exemplo 9

A função de variância é

$$V(\mu) = \frac{\partial \mu}{\partial \theta} = m \frac{e^\theta}{(e^\theta + 1)^2} = \mu(1 - \mu/m) \text{ e } \text{Var}(Y) = \mu(1 - \mu/m).$$

Ou seja, o modelo de regressão, baseado na binomial, supõe que a resposta pode ser heteroscedástica. De acordo com o modelo de regressão binomial, com ligação canônica,

$$\mu = m \frac{e^\eta}{e^\eta + 1} = m \frac{e^{\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p}}{e^{\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p} + 1}.$$

Os coeficientes podem ser interpretados em termos da chance, definida como  $odds(\mu/m) = \frac{\mu}{m-\mu}$  (ver exemplo 3).

## Tópico 6: outros casos particulares

### Continuação do exemplo 9

A chance expressa o número médio de sucessos relativamente ao número médio de fracassos. Se  $odds(\mu/m) = 2$ , por exemplo, então o número médio de sucessos é duas vezes maior do que o número médio de fracassos. Note que

$$\frac{\partial}{\partial x_j} odds(\mu/m) = \beta_j \times odds(\mu/m).$$

Ou seja,  $odds(\mu/m)$  varia exponencialmente com relação a  $x_j$ , a uma taxa de  $\beta_j$  unidades. Note também que

$$e^{\beta_0 + \beta_1 x_1 + \dots + \beta_j (x_j + 1) + \dots + \beta_p x_p} = e^{\beta_j} \times odds(\mu/m).$$

## Tópico 6: outros casos particulares

### Continuação do exemplo 9

Isto é,  $odds(\mu/m)$  varia **multiplicativamente** com relação às preditoras. Se  $\beta_j > 0$ , então, quando  $x_j$  aumenta (diminui) uma unidade, a chance fica  $e^{\beta_j}$  vezes maior (menor). Se  $\beta_j < 0$ , então, quando  $x_j$  aumenta (diminui) uma unidade, a chance fica  $e^{\beta_j}$  vezes menor (maior).



## Referências I

- [1] G. M. Cordeiro e C. G. B. Demétrio, *Modelos lineares generalizados e extensões*, 2013, disponível em <https://docs.ufpr.br/~taconeli/CE22518/LivClarice.pdf>.
- [2] J. A. Nelder and R. W. M. Wedderburn, *Generalized linear models*, Journal of the Royal Statistical Society. Series A (General) **135** (1972), no. 3, 370–384.
- [3] G. A. Paula, *Modelos lineares generalizados com apoio computacional*, 2013, disponível em [https://www.ime.usp.br/~giapaula/texto\\_2013.pdf](https://www.ime.usp.br/~giapaula/texto_2013.pdf).