

## **Modelos lineares generalizados**

**Disciplina ofertada pelo DECAT/UFS**

Código: ESTAT0092

Nível: Graduação

Carga horária: 60h

Período: 2020.2

Professor responsável e ministrante: Luiz Henrique Dore

**Aulas 5 e 6: estimação pelo método da máxima verossimilhança**

# Sumário

- 1 Informações sobre a aula
  - Metas
  - Objetivos
  - Pré-requisitos
- 2 Introdução
- 3 Aula 5
  - Tópico 10: função de log-verossimilhança
  - Tópico 11: função escore
  - Tópico 12: informação de Fisher
- 4 Aula 6
  - Tópico 14: estimador de máxima verossimilhança
  - Tópico 15: método de Newton-Raphson
  - Tópico 16: método escore de Fisher
- 5 Referências

# Metas

- 1 Introduzir o estimador de máxima verossimilhança para o modelo linear generalizado.

# Objetivos

- Após estudar essa aula, o aluno ou aluna será capaz de:
  - 1 calcular a log-verossimilhança do modelo linear generalizado;
  - 2 calcular a função escore do modelo linear generalizado;
  - 3 calcular a informação de Fisher observada e esperada do modelo linear generalizado;
  - 4 obter as equações de estimação correspondentes ao estimador de máxima verossimilhança;
  - 5 encontrar a estimativa de máxima verossimilhança, resolvendo as equações de estimação pelo método de Newton-Raphson ou pelo método escore de Fisher;
  - 6 calcular a estimativa de máxima verossimilhança dos parâmetros de um modelo linear generalizado, usando a função `glm` da plataforma computacional **R**.

# Pré-requisitos

1 Aula 4.

# Introdução

- Na aula 2, viu-se que o processo de modelagem de regressão é constituído por quatro etapas básicas: 1) especificação do modelo; 2) estimação dos parâmetros do modelo; 3) verificação da adequacidade do modelo; 4) aplicação do modelo.
- A aula 4 tratou da etapa 1, a formulação do MLG.
- O MLG é formulado especificando-se três componentes:
  - o componente aleatório, formado pela resposta e sua distribuição de probabilidade, a qual deve pertencer à família exponencial;
  - o componente sistemático, formado pelas variáveis preditoras e pelo preditor linear;
  - a função de ligação, a qual lineariza a relação funcional entre a média e as variáveis preditoras, além de, em geral, garantir que o modelo retorne apenas os valores que a média da resposta pode assumir, de acordo com a distribuição de probabilidade adotada.

# Introdução

- As presentes aulas tratam da etapa 2, a estimação dos parâmetros do modelo.
- Os parâmetros do MLG são estimados pelo método da máxima verossimilhança.
- Na aula 5, são apresentadas as funções de log-verossimilhança e escore e as matrizes de informação de Fisher observada e esperada, elementos necessários para o uso de procedimentos de estimação e inferência por máxima verossimilhança.
- Na aula 6, o estimador de máxima verossimilhança é obtido.
- Em geral, as equações de estimação, que resultam do método da máxima verossimilhança, não possuem solução em forma fechada.

# Introdução

- Desse modo, é necessário aplicar um procedimento numérico para obter as estimativas de máxima verossimilhança.
- Dois procedimentos são considerados.
- O primeiro é o método de Newton-Raphson, o qual utiliza a matriz de informação de Fisher observada;
- O segundo é o método score de Fisher, o qual se baseia na matriz de informação de Fisher esperada.



## Tópico 10: função de log-verossimilhança

- Seja  $Y$  a variável resposta e sejam  $x_1, x_2, \dots, x_p$  as variáveis preditoras.
- Supõe-se que  $Y$  e as variáveis preditoras possuem uma relação governada por um MLG.
- Isto é,  $Y$  é uma variável aleatória tal que
  - ① a distribuição de  $Y$  pertence à família exponencial;
  - ②  $\eta(\mathbf{x}; \boldsymbol{\beta}) = \mathbf{x}^T \boldsymbol{\beta} = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$ ;
  - ③  $g(\mu) = \eta(\mathbf{x}; \boldsymbol{\beta})$ ;

onde  $\mu$  é a média de  $Y$ ,  $g$  é a função de ligação,

$$\mathbf{x} = (1, x_1, \dots, x_p)^T$$

é o vetor de variáveis preditoras e

$$\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^T$$

é o vetor dos coeficientes de regressão.

## Tópico 10: função de log-verossimilhança

- Seja  $\{Y_1, \dots, Y_n\}$  uma amostra aleatória simples de  $Y$ .
- Para cada  $i \in \{1, \dots, n\}$ , sejam  $x_{i1}, \dots, x_{ip}$  os valores das preditoras  $x_1, \dots, x_p$ , respectivamente, correspondentes a  $Y_i$ .
- Nesse caso, supõe-se 1que
  - 1 a distribuição de  $Y_i$  pertence à família exponencial;
  - 2  $\eta(\mathbf{x}_i; \boldsymbol{\beta}) = \mathbf{x}_i^T \boldsymbol{\beta} = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}$ ;
  - 3  $g(\mu_i) = \eta(\mathbf{x}_i; \boldsymbol{\beta}) = \eta_i$ ;

onde  $\mu_i$  é a média de  $Y_i$ ,  $g$  é a função de ligação,

$$\mathbf{x}_i = (1, x_{i1}, \dots, x_{ip})^T$$

é o vetor da  $i$ -ésima observação das variáveis preditoras e

$$\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^T$$

é o vetor dos coeficientes de regressão.

## Tópico 10: função de log-verossimilhança

- Como a distribuição de  $Y_i$  pertence à família exponencial, sua função de densidade (ou função de probabilidade) pode ser escrita como

$$f(y_i; \theta_i, \phi) = \exp \{ \phi^{-1} [y_i \theta_i - b(\theta_i)] + c(y_i, \phi) \}.$$

- O parâmetro canônico varia com as unidades amostrais, pois, como se sabe, ele se relaciona com a média por meio da equação

$$b'(\theta_i) = \mu_i = g^{-1}(\eta_i) = g^{-1}(\mathbf{x}_i^T \boldsymbol{\beta}).$$

- Entretanto, o modelo assume que o parâmetro de dispersão é constante ao longo da amostra.
- Isto é,  $\phi$  não varia de uma unidade amostral para a outra.

## Tópico 10: função de log-verossimilhança

- A função de verossimilhança é dada por

$$\begin{aligned} L(\beta, \phi) &= \prod_{i=1}^n f(Y_i; \theta_i, \phi) = \\ &= \exp \left\{ \phi^{-1} \left( \sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n c(Y_i, \phi) \right\}. \quad (1) \end{aligned}$$

- A função de log-verossimilhança é dada por

$$\begin{aligned} l(\beta, \phi) &= \ln [L(\beta, \phi)] = \sum_{i=1}^n \ln [f(Y_i; \theta_i, \phi)] = \\ &= \phi^{-1} \left( \sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n c(Y_i, \phi). \quad (2) \end{aligned}$$

## Tópico 11: função escore

- A função escore é o gradiente da log-verossimilhança.
- Isto é, denotando por  $\mathbf{U}(\boldsymbol{\beta}, \phi)$  a função escore, tem-se que

$$\mathbf{U}(\boldsymbol{\beta}, \phi) = \left( \frac{\partial l}{\partial \beta_0}, \frac{\partial l}{\partial \beta_1}, \dots, \frac{\partial l}{\partial \beta_p}, \frac{\partial l}{\partial \phi} \right)^T. \quad (3)$$

- As derivadas em (3) são (ver as notas complementares)

$$\frac{\partial l}{\partial \beta_j} = \sum_{i=1}^n \phi^{-1} \sqrt{\frac{\omega_i}{V_i}} (Y_i - \mu_i) x_{ij}, \quad (4)$$

onde  $\omega_i = (\partial \mu_i / \partial \eta_i)^2 / V_i$ ,  $V_i = V(\mu_i)$  e

$$\frac{\partial l}{\partial \phi} = -\phi^{-2} \left( \sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n \frac{\partial c(Y_i, \phi)}{\partial \phi}. \quad (5)$$

## Tópico 11: função escore

- Portanto, a função escore é o vetor

$$\mathbf{U}(\boldsymbol{\beta}, \phi) = \left( \mathbf{U}_{\boldsymbol{\beta}}^T, U_{\phi} \right)^T, \quad (6)$$

onde

$$\mathbf{U}_{\boldsymbol{\beta}} = \left( \frac{\partial l}{\partial \beta_0}, \frac{\partial l}{\partial \beta_1}, \dots, \frac{\partial l}{\partial \beta_p} \right)^T, \quad (7)$$

$$\frac{\partial l}{\partial \beta_j} = \sum_{i=1}^n \phi^{-1} \sqrt{\frac{\omega_i}{V_i}} (Y_i - \mu_i) x_{ij}, \quad (8)$$

$$\omega_i = (\partial \mu_i / \partial \eta_i)^2 / V_i, \quad V_i = V(\mu_i) \quad (9)$$

e

$$U_{\phi} = \frac{\partial l}{\partial \phi} = -\phi^{-2} \left( \sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n \frac{\partial c(Y_i, \phi)}{\partial \phi}. \quad (10)$$

## Tópico 11: função escore

- Sejam  $\mathbf{Y}^T = (Y_1, \dots, Y_n)$  o vetor dos valores de  $Y$  a serem observados e  $\mathbf{X}$  a matriz  $n \times (p + 1)$  definida como

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix} \quad (11)$$

- O vetor  $\mathbf{U}_\beta$  em (7) pode ser escrito como [2, p. 21]

$$\mathbf{U}_\beta = \phi^{-1} \mathbf{X}^T \mathbf{W}^{1/2} \mathbf{V}^{-1/2} (\mathbf{Y} - \boldsymbol{\mu}), \quad (12)$$

onde  $\mathbf{W} = \text{diag}\{\omega_1, \dots, \omega_n\}$ ,  $\mathbf{V} = \text{diag}\{V_1, \dots, V_n\}$  e

$$\mathbf{Y} = (Y_1, \dots, Y_n)^T \quad \text{e} \quad \boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^T.$$

## Tópico 11: função escore

- Se a ligação é canônica, então  $g(\mu_i) = \eta_i = \theta_i$  (ver tópico 5).
- Nesse caso,  $\frac{\partial \mu_i}{\partial \eta_i} = \frac{\partial \mu_i}{\partial \theta_i} = V(\mu_i) = V_i$  (ver tópico 4).
- Portanto,  $\omega_i = (\partial \mu_i / \partial \eta_i)^2 / V_i = V_i^2 / V_i = V_i$  e

$$\mathbf{W} = \text{diag}\{\omega_1, \dots, \omega_n\} = \text{diag}\{V_1, \dots, V_n\} = \mathbf{V}.$$

- Ou seja, se a função de ligação é canônica, então a derivada da log-verossimilhança com relação a  $\beta_l$  em (4) e (8) se torna

$$\frac{\partial l}{\partial \beta_j} = \sum_{i=1}^n \phi^{-1}(Y_i - \mu_i) x_{ij} \quad (13)$$

e  $\mathbf{U}_\beta$  em (12) fica dada por

$$\mathbf{U}_\beta = \phi^{-1} \mathbf{X}^T (\mathbf{Y} - \boldsymbol{\mu}). \quad (14)$$



## Tópico 12: informação de Fisher

- A matriz de informação de Fisher observada, denotada por  $J(\beta, \phi)$ , é o negativo da matriz hessiana da log-verossimilhança.
- Ou seja,

$$J(\beta, \phi) = - \begin{pmatrix} \frac{\partial^2 l}{\partial \beta_0^2} & \frac{\partial^2 l}{\partial \beta_0 \partial \beta_1} & \cdots & \frac{\partial^2 l}{\partial \beta_0 \partial \beta_p} & \frac{\partial^2 l}{\partial \beta_0 \partial \phi} \\ \frac{\partial^2 l}{\partial \beta_1 \partial \beta_0} & \frac{\partial^2 l}{\partial \beta_1^2} & \cdots & \frac{\partial^2 l}{\partial \beta_1 \partial \beta_p} & \frac{\partial^2 l}{\partial \beta_1 \partial \phi} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \frac{\partial^2 l}{\partial \beta_p \partial \beta_0} & \frac{\partial^2 l}{\partial \beta_p \partial \beta_1} & \cdots & \frac{\partial^2 l}{\partial \beta_p^2} & \frac{\partial^2 l}{\partial \beta_p \partial \phi} \\ \frac{\partial^2 l}{\partial \phi \partial \beta_0} & \frac{\partial^2 l}{\partial \phi \partial \beta_1} & \cdots & \frac{\partial^2 l}{\partial \phi \partial \beta_p} & \frac{\partial^2 l}{\partial \phi^2} \end{pmatrix} \quad (15)$$

## Tópico 12: informação de Fisher

- As derivadas parciais em (15) são (ver as notas complementares)

$$\begin{aligned} \frac{\partial^2 l}{\partial \beta_j \partial \beta_l} = & \phi^{-1} \sum_{i=1}^n (Y_i - \mu_i) \frac{\partial^2 \theta_i}{\partial \mu_i^2} \left( \frac{\partial \mu_i}{\partial \eta_i} \right)^2 x_{ij} x_{il} + \\ & + \phi^{-1} \sum_{i=1}^n (Y_i - \mu_i) \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial^2 \mu_i}{\partial \eta_i^2} x_{ij} x_{il} - \phi^{-1} \sum_{i=1}^n \left( \frac{\partial \mu_i}{\partial \eta_i} \right)^2 \frac{\partial \theta_i}{\partial \mu_i} x_{ij} x_{il}; \end{aligned} \quad (16a)$$

$$\frac{\partial^2 l}{\partial \beta_j \partial \phi} = -\phi^{-2} \sum_{i=1}^n \sqrt{\frac{\omega_i}{V_i}} (y_i - \mu_i) x_{ij}; \quad (16b)$$

$$\frac{\partial^2 l}{\partial \phi^2} = 2\phi^{-3} \left( \sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n \frac{\partial^2 c(Y_i, \phi)}{\partial \phi^2}. \quad (16c)$$

## Tópico 12: informação de Fisher

- Pode-se particionar  $J(\beta, \phi)$  como  $J(\beta, \phi) = \begin{pmatrix} J_{\beta\beta} & J_{\beta\phi} \\ J_{\beta\phi}^T & J_{\phi\phi} \end{pmatrix}$ , onde

$$J_{\beta\beta} = - \begin{pmatrix} \frac{\partial^2 l}{\partial \beta_0^2} & \frac{\partial^2 l}{\partial \beta_0 \partial \beta_1} & \cdots & \frac{\partial^2 l}{\partial \beta_0 \partial \beta_p} \\ \frac{\partial^2 l}{\partial \beta_1 \partial \beta_0} & \frac{\partial^2 l}{\partial \beta_1^2} & \cdots & \frac{\partial^2 l}{\partial \beta_1 \partial \beta_p} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 l}{\partial \beta_p \partial \beta_0} & \frac{\partial^2 l}{\partial \beta_p \partial \beta_1} & \cdots & \frac{\partial^2 l}{\partial \beta_p^2} \end{pmatrix}; \quad (17a)$$

$$\begin{aligned} J_{\beta\phi} &= - \left( \frac{\partial^2 l}{\partial \phi \partial \beta_0}, \frac{\partial^2 l}{\partial \phi \partial \beta_1}, \dots, \frac{\partial^2 l}{\partial \phi \partial \beta_p} \right)^T = \\ &= -\phi^{-2} \mathbf{W}^{1/2} \mathbf{V}^{-1/2} (\mathbf{Y} - \boldsymbol{\mu}) \text{ (em notação matricial);} \end{aligned} \quad (17b)$$

$$J_{\phi\phi} = - \frac{\partial^2 l}{\partial \phi^2}. \quad (17c)$$

## Tópico 12: informação de Fisher

- A matriz de informação de Fisher esperada, a qual é denotada por  $\mathbf{K}(\boldsymbol{\beta}, \phi)$ , é o valor esperado da matriz de informação de Fisher observada.
- Isto é,  $\mathbf{K}(\boldsymbol{\beta}, \phi) = E[\mathbf{J}(\boldsymbol{\beta}, \phi)] =$

$$= - \begin{pmatrix} E\left[\frac{\partial^2 l}{\partial \beta_0^2}\right] & E\left[\frac{\partial^2 l}{\partial \beta_0 \partial \beta_1}\right] & \cdots & E\left[\frac{\partial^2 l}{\partial \beta_0 \partial \beta_p}\right] & E\left[\frac{\partial^2 l}{\partial \beta_0 \partial \phi}\right] \\ E\left[\frac{\partial^2 l}{\partial \beta_1 \partial \beta_0}\right] & E\left[\frac{\partial^2 l}{\partial \beta_1^2}\right] & \cdots & E\left[\frac{\partial^2 l}{\partial \beta_1 \partial \beta_p}\right] & E\left[\frac{\partial^2 l}{\partial \beta_1 \partial \phi}\right] \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ E\left[\frac{\partial^2 l}{\partial \beta_p \partial \beta_0}\right] & E\left[\frac{\partial^2 l}{\partial \beta_p \partial \beta_1}\right] & \cdots & E\left[\frac{\partial^2 l}{\partial \beta_p^2}\right] & E\left[\frac{\partial^2 l}{\partial \beta_p \partial \phi}\right] \\ E\left[\frac{\partial^2 l}{\partial \phi \partial \beta_0}\right] & E\left[\frac{\partial^2 l}{\partial \phi \partial \beta_1}\right] & \cdots & E\left[\frac{\partial^2 l}{\partial \phi \partial \beta_p}\right] & E\left[\frac{\partial^2 l}{\partial \phi^2}\right] \end{pmatrix}. \quad (18)$$

## Tópico 12: informação de Fisher

- As esperanças em (18) são (ver as notas complementares)

$$E \left[ \frac{\partial^2 l}{\partial \beta_j \partial \beta_l} \right] = -\phi^{-1} \sum_{i=1}^n \omega_i x_{ij} x_{il}; \quad (19a)$$

$$E \left[ \frac{\partial^2 l}{\partial \beta_j \partial \phi} \right] = 0; \quad (19b)$$

$$E \left[ \frac{\partial^2 l}{\partial \phi^2} \right] = 2\phi^{-3} \left( \sum_{i=1}^n \mu_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n E \left( \frac{\partial^2 c(Y_i, \phi)}{\partial \phi^2} \right). \quad (19c)$$

## Tópico 12: informação de Fisher

- Pode-se particionar  $\mathbf{K}(\boldsymbol{\beta}, \phi)$  como  $\mathbf{K}(\boldsymbol{\beta}, \phi) = \begin{pmatrix} \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} & \mathbf{K}_{\boldsymbol{\beta}\phi} \\ \mathbf{K}_{\boldsymbol{\beta}\phi}^T & K_{\phi\phi} \end{pmatrix}$ , onde

$$\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = - \begin{pmatrix} E \left[ \frac{\partial^2 l}{\partial \beta_0^2} \right] & E \left[ \frac{\partial^2 l}{\partial \beta_0 \partial \beta_1} \right] & \cdots & E \left[ \frac{\partial^2 l}{\partial \beta_0 \partial \beta_p} \right] \\ E \left[ \frac{\partial^2 l}{\partial \beta_1 \partial \beta_0} \right] & E \left[ \frac{\partial^2 l}{\partial \beta_1^2} \right] & \cdots & E \left[ \frac{\partial^2 l}{\partial \beta_1 \partial \beta_p} \right] \\ \vdots & \vdots & \ddots & \vdots \\ E \left[ \frac{\partial^2 l}{\partial \beta_p \partial \beta_0} \right] & E \left[ \frac{\partial^2 l}{\partial \beta_p \partial \beta_1} \right] & \cdots & E \left[ \frac{\partial^2 l}{\partial \beta_p^2} \right] \end{pmatrix} = E [\mathbf{J}_{\boldsymbol{\beta}\boldsymbol{\beta}}]; \quad (20a)$$

$$\mathbf{K}_{\boldsymbol{\beta}\phi} = - \left( E \left[ \frac{\partial^2 l}{\partial \phi \partial \beta_0} \right], E \left[ \frac{\partial^2 l}{\partial \phi \partial \beta_1} \right], \dots, E \left[ \frac{\partial^2 l}{\partial \phi \partial \beta_p} \right] \right)^T = E [\mathbf{J}_{\boldsymbol{\beta}\phi}]; \quad (20b)$$

$$K_{\phi\phi} = -E \left[ \frac{\partial^2 l}{\partial \phi^2} \right] = E [J_{\phi\phi}]. \quad (20c)$$

## Tópico 12: informação de Fisher

- O termo  $K_{\beta\beta}$  pode ser escrito como [2, p. 22]

$$K_{\beta\beta} = \phi^{-1} \mathbf{X}^T \mathbf{W} \mathbf{X}. \quad (21)$$

- Pela equação (19b),

$$K_{\beta\phi} = \underset{(p+1) \times 1}{\mathbf{O}}, \quad (22)$$

onde  $\underset{(p+1) \times 1}{\mathbf{O}}$  é o vetor-coluna de zeros de dimensão  $p + 1$ .

- Logo,  $K(\beta, \phi)$  é

$$K(\beta, \phi) = \begin{pmatrix} K_{\beta\beta} & K_{\beta\phi} \\ K_{\beta\phi}^T & K_{\phi\phi} \end{pmatrix} = \begin{pmatrix} \phi^{-1} \mathbf{X}^T \mathbf{W} \mathbf{X} & \underset{(p+1) \times 1}{\mathbf{O}} \\ \underset{1 \times (p+1)}{\mathbf{O}} & K_{\phi\phi} \end{pmatrix}, \quad (23)$$

onde  $K_{\phi\phi}$  é dado por (20c) e (19c).

## Tópico 12: informação de Fisher

- Se a ligação é canônica, então

$$\mathbf{J}_{\beta\phi} = -\phi^{-2} \mathbf{X}^T (\mathbf{Y} - \boldsymbol{\mu}), \quad (24a)$$

$$\mathbf{K}_{\beta\beta} = \phi^{-1} \mathbf{X}^T \mathbf{V} \mathbf{X}; \quad (24b)$$

$$\mathbf{J}_{\beta\beta} = \mathbf{K}_{\beta\beta}. \quad (24c)$$

- De fato, conforme visto no tópico 11, supondo uma ligação canônica, tem-se que  $\mathbf{W} = \mathbf{V}$ .
- As expressões (24a) e (24b) são obtidas fazendo a substituição de  $\mathbf{W}$  por  $\mathbf{V}$  em (17b) e (21), respectivamente.
- Além disso, supondo que a ligação é canônica, a derivada da log-verossimilhança com relação a  $\beta_j$  fica dada por (13).



## Tópico 12: informação de Fisher

- Calculando  $\frac{\partial^2 l}{\partial \beta_j \partial \beta_l}$  a partir de (13), obtém-se

$$\frac{\partial^2 l}{\partial \beta_j \partial \beta_l} = - \sum_{i=1}^n \phi^{-1} \frac{\partial \mu_i}{\partial \beta_l} x_{ij}.$$

- Dessa forma,

$$E \left[ \frac{\partial^2 l}{\partial \beta_j \partial \beta_l} \right] = \frac{\partial^2 l}{\partial \beta_j \partial \beta_l} = - \sum_{i=1}^n \phi^{-1} \frac{\partial \mu_i}{\partial \beta_l} x_{ij},$$

pois  $\frac{\partial^2 l}{\partial \beta_j \partial \beta_l}$  não depende de  $Y_1, \dots, Y_n$ .

- Segue-se que (ver as expressões 17a e 20a)

$$\mathbf{K}_{\beta\beta} = E[\mathbf{J}_{\beta\beta}] = \mathbf{J}_{\beta\beta}.$$

## Tópico 12: informação de Fisher

### Exemplo 1

Para o modelo linear normal (exemplo 1, tópico 4), tem-se que

$$\theta_i = \mu_i, \quad b(\theta_i) = \frac{\theta_i^2}{2}, \quad \phi = \sigma^2 \quad \text{e} \quad c(y_i, \phi) = -\frac{y_i^2}{2\phi} - \frac{1}{2} \ln(2\pi\phi).$$

Além disso,  $V_i = V(\mu_i) = 1$  e  $g(\mu_i) = \mu_i = \eta_i = \mathbf{x}_i^T \boldsymbol{\beta}$ . Logo,

$$\mathbf{V} = \text{diag}\{1, \dots, 1\} = \mathbf{I}_n \quad \text{e} \quad \boldsymbol{\mu} = (\mathbf{x}_1^T \boldsymbol{\beta}, \dots, \mathbf{x}_n^T \boldsymbol{\beta}).$$

Como a ligação é canônica (exemplo 4, tópico 5), tem-se que

$$\mathbf{U}_{\boldsymbol{\beta}} = \phi^{-1} \mathbf{X}^T (\mathbf{Y} - \boldsymbol{\mu}) \quad \text{e} \quad \mathbf{J}_{\boldsymbol{\beta}\phi} = -\phi^{-2} \mathbf{X}^T (\mathbf{Y} - \boldsymbol{\mu}).$$

## Tópico 12: informação de Fisher

### Continuação do exemplo 1

Tem-se também que

$$\mathbf{J}_{\beta\beta} = \mathbf{K}_{\beta\beta} = \phi^{-1} \mathbf{X}^T \mathbf{V} \mathbf{X} = \phi^{-1} \mathbf{X}^T \mathbf{X}.$$

Resta calcular  $U_\phi$ ,  $J_{\phi\phi}$  e  $K_{\phi\phi}$ . A derivada de  $c(y_i, \phi)$  com relação a  $\phi$  é

$$\frac{\partial c(y_i, \phi)}{\partial \phi} = \frac{y_i^2}{2\phi^2} - \frac{1}{2\phi}.$$

Com isso,

$$\begin{aligned} U_\phi &= -\phi^{-2} \left( \sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n \frac{\partial c(Y_i, \phi)}{\partial \phi} = \\ &= -\frac{1}{\phi^2} \left( \sum_{i=1}^n Y_i \mu_i - \sum_{i=1}^n \frac{\mu_i^2}{2} \right) + \sum_{i=1}^n \frac{Y_i^2}{2\phi^2} - \frac{n}{2\phi}. \end{aligned}$$

## Tópico 12: informação de Fisher

### Continuação do exemplo 1

A última expressão acima pode ser escrita como

$$\begin{aligned}U_{\phi} &= \frac{1}{2\phi^2} \sum_{i=1}^n (-2Y_i\mu_i + \mu_i^2 + Y_i^2) - \frac{n}{2\phi} = \\&= \frac{1}{2\phi^2} \sum_{i=1}^n (Y_i - \mu_i)^2 - \frac{n}{2\phi}.\end{aligned}$$

A segunda derivada de  $c(y_i, \phi)$  com relação a  $\phi$  é

$$\frac{\partial^2 c(y_i, \phi)}{\partial \phi^2} = -\frac{y_i^2}{\phi^3} + \frac{1}{2\phi^2}.$$

## Tópico 12: informação de Fisher

### Continuação do exemplo 1

Logo,

$$\begin{aligned} J_{\phi\phi} &= -2\phi^{-3} \left( \sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) - \sum_{i=1}^n \frac{\partial^2 c(Y_i, \phi)}{\partial \phi^2} = \\ &= -\frac{2}{\phi^3} \left( \sum_{i=1}^n Y_i \mu_i - \sum_{i=1}^n \frac{\mu_i^2}{2} \right) + \sum_{i=1}^n \frac{Y_i^2}{\phi^3} - \frac{n}{2\phi^2} = \\ &= \frac{1}{\phi^3} \sum_{i=1}^n (-2Y_i \mu_i + \mu_i^2 + Y_i^2) - \frac{n}{2\phi^2} = \\ &= \frac{1}{\phi^3} \sum_{i=1}^n (Y_i - \mu_i)^2 - \frac{n}{2\phi^2}. \end{aligned}$$

## Tópico 12: informação de Fisher

### Continuação do exemplo 1

Segue-se que

$$\begin{aligned} K_{\phi\phi} &= E[J_{\phi\phi}] = \frac{1}{\phi^3} \sum_{i=1}^n E[(Y_i - \mu_i)]^2 - \frac{n}{2\phi^2} = \\ &= \frac{1}{\phi^3} \sum_{i=1}^n \text{Var}(Y_i) - \frac{n}{2\phi^2}. \end{aligned}$$

Como  $\text{Var}(Y_i) = \sigma^2 = \phi$  (exemplo 1, tópico 4), tem-se que

$$K_{\phi\phi} = \frac{n}{\phi^2} - \frac{n}{2\phi^2} = \frac{n}{2\phi^2}.$$

## Tópico 12: informação de Fisher

### Exemplo 2

Para o modelo de regressão Poisson (exemplo 2, aula 3)

$$\theta_i = \ln(\mu_i), \quad b(\theta_i) = e^{\theta_i}, \quad \phi = 1 \text{ e } c(y_i, \phi) = -\ln(y_i!) (2\pi\phi).$$

Além disso,  $V_i = V(\mu_i) = \mu_i$  e  $\mu_i = e^{\eta_i} = e^{\mathbf{x}_i^T \boldsymbol{\beta}}$ . Logo,

$$\mathbf{V} = \text{diag} \left\{ e^{\mathbf{x}_1^T \boldsymbol{\beta}}, \dots, e^{\mathbf{x}_n^T \boldsymbol{\beta}} \right\} \quad \text{e} \quad \boldsymbol{\mu} = \left( e^{\mathbf{x}_1^T \boldsymbol{\beta}}, \dots, e^{\mathbf{x}_n^T \boldsymbol{\beta}} \right).$$

Como  $\phi$  é conhecido, os termos da função escore e das matrizes de informação que contêm  $\phi$  devem ser ignorados. Ou seja,

$$\mathbf{U}(\boldsymbol{\beta}, \phi) = \mathbf{U}_{\boldsymbol{\beta}}, \quad \mathbf{J}(\boldsymbol{\beta}, \phi) = \mathbf{J}_{\boldsymbol{\beta}\boldsymbol{\beta}} \quad \text{e} \quad \mathbf{K}(\boldsymbol{\beta}, \phi) = \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}.$$

## Tópico 12: informação de Fisher

### Continuação do exemplo 2

A ligação é canônica (exemplo 6, tópico 5) e  $\phi = 1$ . Logo,

$$\mathbf{U}_{\beta} = \mathbf{X}^T (\mathbf{Y} - \boldsymbol{\mu}) \quad \text{e} \quad \mathbf{J}_{\beta\beta} = \mathbf{K}_{\beta\beta} = \mathbf{X}^T \mathbf{V} \mathbf{X}.$$

### Exemplo 3

Para o modelo de regressão logística (exemplo 3, tópico 4)

$$\theta_i = \ln \left( \frac{\mu_i}{1 - \mu_i} \right), \quad b(\theta_i) = \ln(1 + e^{\theta_i}), \quad \phi = 1 \text{ e } c(y_i; \phi) = 0.$$

Além disso,  $V_i = V(\mu_i) = \mu_i(1 - \mu_i)$  e  $\mu_i = \frac{e^{\eta_i}}{e^{\eta_i} + 1}$ .



## Tópico 12: informação de Fisher

### Continuação do exemplo 3

Portanto,

$$\boldsymbol{\mu} = (\mu_1, \dots, \mu_n) \quad \text{e} \quad \mathbf{V} = \text{diag} \{V_1, \dots, V_n\},$$

onde  $\mu_i = \frac{e^{\eta_i}}{e^{\eta_i} + 1}$  e  $V_i = \mu_i(1 - \mu_i) = \frac{e^{\eta_i}}{(e^{\eta_i} + 1)^2}$ . Como  $\phi$  é conhecido, os termos da função escore e das matrizes de informação que contêm  $\phi$  devem ser ignorados. Ou seja,

$$\mathbf{U}(\boldsymbol{\beta}, \phi) = \mathbf{U}_{\boldsymbol{\beta}}, \quad \mathbf{J}(\boldsymbol{\beta}, \phi) = \mathbf{J}_{\boldsymbol{\beta}\boldsymbol{\beta}} \quad \text{e} \quad \mathbf{K}(\boldsymbol{\beta}, \phi) = \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}.$$

A ligação é canônica (exemplo 6, tópico 5) e  $\phi = 1$ . Logo,

$$\mathbf{U}_{\boldsymbol{\beta}} = \mathbf{X}^T (\mathbf{Y} - \boldsymbol{\mu}) \quad \text{e} \quad \mathbf{J}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \mathbf{X}^T \mathbf{V} \mathbf{X}.$$

## Tópico 12: informação de Fisher

### Exemplo 4

Para o modelo de regressão gama, com ligação logarítmica, tem-se que (exemplos 7 e 8, aula 3)

$$\theta_i = -\frac{1}{\mu_i}, \quad b(\theta_i) = -\ln(-\theta_i), \quad \phi = a^{-1}$$

e

$$c(y_i, \phi) = \phi^{-1} \ln(\phi^{-1}) - \ln \Gamma(\phi^{-1}) + (\phi^{-1} - 1) \ln(y_i).$$

Além disso,  $V_i = V(\mu_i) = \mu_i^2$  e  $\mu_i = e^{\eta_i} = e^{\mathbf{x}_i^T \boldsymbol{\beta}}$ . Portanto,

$$\mathbf{V} = \text{diag}\{e^{2\mathbf{x}_1^T \boldsymbol{\beta}}, \dots, e^{2\mathbf{x}_n^T \boldsymbol{\beta}}\}.$$

A ligação não é canônica. Logo, é necessário calcular  $\mathbf{W}$ .

## Tópico 12: informação de Fisher

### Continuação do exemplo 4

Como  $\frac{\partial \mu_i}{\partial \eta_i} = \mu_i$ , tem-se que

$$\omega_i = (\partial \mu_i / \partial \eta_i)^2 / V_i = \mu_i^2 / \mu_i^2 = 1.$$

Segue-se que  $\mathbf{W} = \text{diag}\{1, \dots, 1\} = \mathbf{I}_n$ . Com isso,

$$\mathbf{U}_\beta = \phi^{-1} \mathbf{X}^T \mathbf{V}^{-1/2} (\mathbf{Y} - \boldsymbol{\mu}),$$

$$\mathbf{J}_{\beta\phi} = \phi^{-2} \mathbf{X}^T \mathbf{V}^{-1/2} (\mathbf{Y} - \boldsymbol{\mu}) \quad \text{e} \quad \mathbf{K}_{\beta\beta} = \phi^{-1} \mathbf{X}^T \mathbf{X}.$$

A derivada de  $c(y_i, \phi)$  com relação a  $\phi$  é

$$\frac{\partial c(y_i, \phi)}{\partial \phi} = -\phi^{-2} (\ln(\phi^{-1}) + 1 - \psi(\phi^{-1}) + \ln(y_i)),$$

onde  $\psi(x) = \frac{\partial \ln \Gamma(x)}{\partial x} = \frac{\Gamma'(x)}{\Gamma(x)}$  é a função digama.

## Tópico 12: informação de Fisher

### Continuação do exemplo 4

Lembrando que  $\theta_i = -\frac{1}{\mu_i}$  e  $b(\theta_i) = -\ln(-\theta_i) = \ln(\mu_i)$ , tem-se

$$\begin{aligned} U_{\phi} &= -\phi^{-2} \left( \sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n \frac{\partial c(Y_i, \phi)}{\partial \phi} = \\ &= \phi^{-2} \left( \sum_{i=1}^n \frac{Y_i}{\mu_i} + \sum_{i=1}^n \ln(\mu_i) \right) - \phi^{-2} \sum_{i=1}^n \ln(Y_i) - n\phi^{-2} - \\ &\quad - n\phi^{-2} (\ln(\phi^{-1}) - \psi(\phi^{-1})) = \\ &= \phi^{-2} \sum_{i=1}^n \left[ \frac{Y_i - \mu_i}{\mu_i} + \ln \left( \frac{\mu_i}{Y_i} \right) \right] - n\phi^{-2} (\ln(\phi^{-1}) - \psi(\phi^{-1})). \end{aligned}$$

## Tópico 12: informação de Fisher

### Continuação do exemplo 4

As derivadas necessárias para obter  $\mathbf{J}_{\beta\beta}$  são

$$\frac{\partial \mu_i}{\partial \eta_i} = \mu_i, \quad \frac{\partial^2 \mu_i}{\partial \eta_i^2} = \mu_i, \quad \frac{\partial \theta_i}{\partial \mu_i} = \frac{1}{\mu_i^2}, \quad \text{e} \quad \frac{\partial^2 \theta_i}{\partial \mu_i^2} = -\frac{2}{\mu_i^3}.$$

Substituindo esses valores em (16a), obtém-se

$$\frac{\partial^2 l}{\partial \beta_j \partial \beta_l} = -\phi^{-1} \sum_{i=1}^n (Y_i - \mu_i) x_{ij} x_{il} - \phi^{-1} \sum_{i=1}^n x_{ij} x_{il}.$$

Portanto, o elemento  $(j, l)$  da matriz  $\mathbf{J}_{\beta\beta}$  em (17a) é

$$J_{\beta_j \beta_l} = -\frac{\partial^2 l}{\partial \beta_j \partial \beta_l} = \phi^{-1} \sum_{i=1}^n (Y_i - \mu_i) x_{ij} x_{il} + \phi^{-1} \sum_{i=1}^n x_{ij} x_{il}.$$

## Tópico 12: informação de Fisher

### Continuação do exemplo 4

Em notação matricial,  $J_{\beta\beta}$  pode ser escrita como

$$J_{\beta\beta} = \phi^{-1} \mathbf{X}^T \boldsymbol{\varepsilon} \mathbf{X} + \phi^{-1} \mathbf{X}^T \mathbf{X},$$

onde

$$\boldsymbol{\varepsilon} = \text{diag}\{Y_1 - \mu_1, \dots, Y_n - \mu_n\}.$$

A segunda derivada de  $c(Y_i, \phi)$  com relação a  $\phi$  é

$$\frac{\partial^2 c(Y_i, \phi)}{\partial \phi^2} = -2\phi^{-1} \frac{\partial c(Y_i, \phi)}{\partial \phi} + \phi^{-4}(\phi - \psi'(\phi^{-1})),$$

onde  $\psi'(x) = \frac{\partial \psi(x)}{\partial x}$  é a função trigama.

## Tópico 12: informação de Fisher

### Continuação do exemplo 4

Substituindo em (16c), obtém-se

$$\begin{aligned}\frac{\partial^2 l}{\partial \phi^2} &= 2\phi^{-3} \left( \sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n \frac{\partial^2 c(Y_i, \phi)}{\partial \phi^2} = \\ &= 2\phi^{-3} \left( \sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) - 2\phi^{-1} \sum_{i=1}^n \frac{\partial c(Y_i, \phi)}{\partial \phi} + \\ &+ n\phi^{-4}(\phi - \psi'(\phi^{-1})) = \\ &= -2\phi^{-1} \left[ -\phi^{-2} \left( \sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n \frac{\partial c(Y_i, \phi)}{\partial \phi} \right] + \\ &+ n\phi^{-4}(\phi - \psi'(\phi^{-1})).\end{aligned}$$

## Tópico 12: informação de Fisher

### Continuação do exemplo 4

Comparando essa última expressão com (10), tem-se que

$$\frac{\partial^2 l}{\partial \phi^2} = -2\phi^{-1}U_\phi + n\phi^{-4}(\phi - \psi'(\phi^{-1})).$$

Portanto,  $J_{\phi\phi}$  em (17c) é

$$J_{\phi\phi} = -\frac{\partial^2 l}{\partial \phi^2} = 2\phi^{-1}U_\phi + n\phi^{-4}(\psi'(\phi^{-1}) - \phi).$$

Segue-se que

$$K_{\phi\phi} = E(J_{\phi\phi}) = 2\phi^{-1}E(U_\phi) + n\phi^{-4}(\psi'(\phi) - \phi) = n\phi^{-4}(\psi'(\phi) - \phi),$$

pois  $E(U_\phi) = 0$  (ver as notas complementares).



## Tópico 14: estimador de máxima verossimilhança

- Os estimadores de máxima verossimilhança de  $\beta$  e  $\phi$  são os valores desses parâmetros que maximizam a log-verossimilhança.
- Sejam  $\hat{\beta}$  e  $\hat{\phi}$  os estimadores de máxima verossimilhança de  $\beta$  e  $\phi$ , respectivamente.
- Os valores de  $\hat{\beta}$  e  $\hat{\phi}$  são obtidos como solução da equação

$$U(\beta, \phi) = 0.$$

- Usando (6), (10) e (12), a equação de estimação acima pode ser escrita como

$$\begin{cases} U_{\beta} = \phi^{-1} \mathbf{X}^T \mathbf{W}^{1/2} \mathbf{V}^{-1/2} (\mathbf{Y} - \mu) = 0 \\ U_{\phi} = -\phi^{-2} \left( \sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n \frac{\partial c(Y_i, \phi)}{\partial \phi} = 0. \end{cases}$$

## Tópico 14: estimador de máxima verossimilhança

- A equação  $\mathbf{U}_\beta = 0$  equivale a

$$\mathbf{X}^T \mathbf{W}^{1/2} \mathbf{V}^{-1/2} (\mathbf{Y} - \boldsymbol{\mu}) = 0.$$

- Como  $\mathbf{W}$ ,  $\mathbf{V}$  e  $\boldsymbol{\mu}$  dependem apenas de  $\beta$ , o estimador de máxima verossimilhança de  $\beta$  pode ser encontrado como a solução da equação  $\mathbf{U}_\beta = 0$ , independentemente de  $\phi$ .
- Ou seja,  $\hat{\beta}$  é a solução da equação

$$\mathbf{X}^T \mathbf{W}^{1/2} \mathbf{V}^{-1/2} \boldsymbol{\mu} = \mathbf{X}^T \mathbf{W}^{1/2} \mathbf{V}^{-1/2} \mathbf{Y}. \quad (26)$$

- Quando a ligação é canônica,  $\mathbf{W} = \mathbf{V}$  (ver tópico 11).
- Logo, se a ligação é canônica,  $\hat{\beta}$  é a solução da equação

$$\mathbf{X}^T \boldsymbol{\mu} = \mathbf{X}^T \mathbf{Y}. \quad (27)$$

## Tópico 14: estimador de máxima verossimilhança

- Já o estimador de máxima verossimilhança de  $\phi$ , em geral, depende do valor de  $\beta$ .
- A equação  $U_\phi = 0$  equivale a

$$\sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) = \phi^2 \sum_{i=1}^n \frac{\partial c(Y_i, \phi)}{\partial \phi}. \quad (28)$$

- Como  $b'(\theta_i) = \mu_i = g^{-1}(\eta_i) = g^{-1}(\mathbf{x}_i^T \beta)$ , pode-se concluir que  $\theta_i$  depende de  $\beta$ .
- $\hat{\phi}$  é a solução da equação (28) com  $\hat{\beta}$  no lugar de  $\beta$ .
- Em resumo, os estimadores de máxima verossimilhança são obtidos da seguinte forma:
  - 1 calcula-se  $\hat{\beta}$  como solução de (26) ou de (27);
  - 2 calcula-se  $\hat{\phi}$  como solução de (28) com  $\hat{\beta}$  no lugar de  $\beta$ .

## Tópico 14: estimador de máxima verossimilhança

- Os estimadores de máxima verossimilhança de  $\eta_i$  e de  $\mu_i$  são

$$\hat{\eta}_i = \mathbf{x}_i^T \hat{\boldsymbol{\beta}} \quad (29)$$

e

$$\hat{\mu}_i = g^{-1}(\hat{\eta}_i) = g^{-1}(\mathbf{x}_i^T \hat{\boldsymbol{\beta}}). \quad (30)$$

- O estimador de máxima verossimilhança de  $\boldsymbol{\mu}$  é

$$\hat{\boldsymbol{\mu}} = (\hat{\mu}_1, \dots, \hat{\mu}_n)^T. \quad (31)$$

- Seja  $\boldsymbol{\eta}$  o vetor de preditores lineares

$$\boldsymbol{\eta} = (\eta_1, \dots, \eta_n)^T = \left( \mathbf{x}_1^T \boldsymbol{\beta}, \dots, \mathbf{x}_n^T \boldsymbol{\beta} \right)^T. \quad (32)$$

## Tópico 14: estimador de máxima verossimilhança

- Em notação matricial,  $\eta$  pode ser escrito como

$$\eta = \mathbf{X}^T \beta, \quad (33)$$

onde  $\mathbf{X}$  é a matriz (11).

- O estimador de máxima verossimilhança de  $\eta$  é

$$\hat{\eta} = \mathbf{X}^T \hat{\beta}. \quad (34)$$

- Quando  $\phi$  é conhecido, como no caso das distribuições de Poisson e de Bernoulli, apenas  $\beta$  precisa ser estimado.

## Tópico 14: estimador de máxima verossimilhança

### Exemplo 5

No caso do modelo linear normal, a função de ligação é canônica. Logo,  $\hat{\beta}$  é a solução de (27). Para o modelo linear normal tem-se que  $\mu_i = \eta_i = \mathbf{x}_i^T \beta$ . Em notação matricial,

$$\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^T = \boldsymbol{\eta} = \mathbf{X}\boldsymbol{\beta},$$

Substituindo em (27), obtém-se

$$\mathbf{X}^T \boldsymbol{\mu} = \mathbf{X}^T \mathbf{Y} \Leftrightarrow \mathbf{X}^T \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^T \mathbf{Y} \Leftrightarrow \boldsymbol{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}.$$

Portanto, no caso do modelo linear normal,

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}.$$

## Tópico 14: estimador de máxima verossimilhança

### Continuação do exemplo 5

Viu-se no exemplo 1 que

$$U_{\phi} = \frac{1}{2\phi^2} \sum_{i=1}^n (Y_i - \mu_i)^2 - \frac{n}{2\phi}.$$

$U_{\phi} = 0$  implica que

$$\frac{1}{2\phi^2} \sum_{i=1}^n (Y_i - \mu_i)^2 - \frac{n}{2\phi} = 0 \Leftrightarrow \phi = \frac{1}{n} \sum_{i=1}^n (Y_i - \mu_i)^2.$$

Ou seja, no caso do modelo linear normal

$$\hat{\phi} = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{\mu}_i)^2,$$

onde  $\hat{\mu}_i = \hat{\eta}_i = \mathbf{x}_i^T \hat{\boldsymbol{\beta}} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \cdots + \hat{\beta}_p x_p$ .

## Tópico 14: estimador de máxima verossimilhança

### Exemplo 6

No caso do modelo de regressão Poisson, a função de ligação é canônica. Logo,  $\hat{\beta}$  é a solução de (27). No modelo de regressão Poisson,  $\mu_i = e^{\eta_i} = e^{x_i^T \beta}$ . Ou seja,  $\hat{\beta}$  é a solução de

$$\mathbf{X}^T \boldsymbol{\mu} = \mathbf{X}^T \mathbf{Y}.$$

com

$$\boldsymbol{\mu} = \left( e^{x_1^T \beta}, \dots, e^{x_n^T \beta} \right)^T.$$

Essa equação não tem solução analítica. Nesse caso,  $\hat{\beta}$  deve ser calculado utilizando um procedimento numérico. Não é preciso estimar  $\phi$ , pois, no caso da distribuição de Poisson,  $\phi = 1$ .



## Tópico 14: estimador de máxima verossimilhança

### Exemplo 7

No caso do modelo de regressão logística, a função de ligação é canônica. Logo,  $\hat{\beta}$  é a solução de (27). No modelo de regressão logística,  $\mu_i = \frac{e^{\eta_i}}{e^{\eta_i} + 1} = \frac{e^{x_i^T \beta}}{e^{x_i^T \beta} + 1}$ . Ou seja,  $\hat{\beta}$  é a solução de

$$\mathbf{X}^T \boldsymbol{\mu} = \mathbf{X}^T \mathbf{Y}, \quad \text{com} \quad \boldsymbol{\mu} = \left( \frac{e^{x_1^T \beta}}{e^{x_1^T \beta} + 1}, \dots, \frac{e^{x_n^T \beta}}{e^{x_n^T \beta} + 1} \right)^T.$$

Essa equação não tem solução analítica. Nesse caso,  $\hat{\beta}$  deve ser calculado utilizando um procedimento numérico. Não é preciso estimar  $\phi$ , pois, no caso da distribuição de Bernoulli,  $\phi = 1$ .

## Tópico 14: estimador de máxima verossimilhança

### Exemplo 8

Como a ligação exponencial não é a ligação canônica da distribuição gama, no caso do modelo de regressão Gama com ligação exponencial,  $\hat{\beta}$  é a solução de (26). Sabe-se que, nesse modelo,  $\mu_i = e^{\eta_i} = e^{\mathbf{x}_i^T \beta}$ . Viu-se no exemplo 4 que

$$\mathbf{V} = \text{diag}\{\mu_1^2, \dots, \mu_n^2\} \quad \text{e} \quad \mathbf{W} = \text{diag}\{1, \dots, 1\} = \mathbf{I}_n$$

Portanto,  $\hat{\beta}$  é a solução de

$$\mathbf{X}^T \mathbf{V}^{-1/2} \boldsymbol{\mu} = \mathbf{X}^T \mathbf{V}^{-1/2} \mathbf{Y}.$$

com

$$\boldsymbol{\mu} = \left( e^{\mathbf{x}_1^T \beta}, \dots, e^{\mathbf{x}_n^T \beta} \right)^T \quad \text{e} \quad \mathbf{V} = \left\{ e^{2\mathbf{x}_1^T \beta}, \dots, e^{2\mathbf{x}_n^T \beta} \right\}.$$

## Tópico 14: estimador de máxima verossimilhança

### Continuação do exemplo 8

Essa equação não tem solução analítica. Nesse caso,  $\hat{\beta}$  deve ser calculado utilizando um procedimento numérico. Uma vez que  $\hat{\beta}$  tenha sido calculado, passa-se ao cálculo de  $\hat{\phi}$ . Viu-se, no exemplo 4, que

$$U_{\phi} = \phi^{-2} \left[ \sum_{i=1}^n \frac{Y_i - \mu_i}{\mu_i} + \sum_{i=1}^n \ln \left( \frac{\mu_i}{Y_i} \right) \right] - n\phi^{-2} (\ln(\phi^{-1}) - \psi(\phi^{-1})).$$

$\hat{\phi}$  é a solução de  $U_{\phi} = 0$  com  $\hat{\beta}$  no lugar de  $\beta$ .  $U_{\phi} = 0$  implica

$$\frac{1}{n} \sum_{i=1}^n \left[ \frac{Y_i - \mu_i}{\mu_i} + \ln \left( \frac{\mu_i}{Y_i} \right) \right] = \ln(\phi^{-1}) - \psi(\phi^{-1}).$$

## Tópico 14: estimador de máxima verossimilhança

### Continuação do exemplo 8

Portanto,  $\hat{\phi}$  é a solução de

$$\frac{1}{n} \sum_{i=1}^n \left[ \frac{Y_i - \hat{\mu}_i}{\hat{\mu}_i} + \ln \left( \frac{\hat{\mu}_i}{Y_i} \right) \right] = \ln(\phi^{-1}) - \psi(\phi^{-1}).$$

Essa equação não tem solução analítica. Nesse caso,  $\hat{\phi}$  deve ser calculado utilizando um procedimento numérico.

## Tópico 15: método de Newton-Raphson

- O estimador de máxima verossimilhança de  $\beta$ , conforme visto no tópico 14, é a solução da equação (26).
- Viu-se também que  $\hat{\phi}$ , o estimador de máxima verossimilhança de  $\phi$ , é a solução da equação (28), com  $\hat{\beta}$  no lugar de  $\beta$ .
- Acontece que nem sempre essas equações possuem uma solução analítica, isto é, uma solução em forma fechada.
- Isso foi mencionado nos exemplos (7) e (8).
- Em casos como esses, é necessário utilizar um procedimento numérico para encontrar as soluções dessas equações.
- Um método que pode ser utilizado com essa finalidade é o método de Newton-Raphson [1, p. 72].

## Tópico 15: método de Newton-Raphson

- Seja  $h : (a, b) \rightarrow \mathbb{R}$  uma função real diferenciável em  $(a, b)$ .
- Deseja-se encontrar a solução da equação  $h(x) = 0$ .
- Seja  $x_0 \in (a, b)$  um valor aproximado para essa solução.
- A aproximação de Taylor de ordem 1 de  $h$ , em torno de  $x_0$ , é

$$h(x) \approx h(x_0) + h'(x_0)(x - x_0).$$

- O método de Newton-Raphson propõe resolver  $h(x) = 0$ , de forma aproximada, substituindo  $h(x)$  por sua aproximação de Taylor de ordem 1.
- Nesse caso,

$$h(x_0) + h'(x_0)(x - x_0) = 0 \Rightarrow x = x_0 - \frac{h(x_0)}{h'(x_0)}.$$

## Tópico 15: método de Newton-Raphson

- Se  $x_0$  é suficientemente próximo da solução de  $h(x) = 0$  e se a função  $h$  satisfaz certas condições, então  $x = x_0 - \frac{h(x_0)}{h'(x_0)}$  é uma aproximação para a solução de  $h(x) = 0$  melhor do que  $x_0$ .
- Fazendo  $x_1 = x_0 - \frac{h(x_0)}{h'(x_0)}$ , com base nesse mesmo raciocínio, obtém-se que  $x_2 = x_1 - \frac{h(x_1)}{h'(x_1)}$  é uma aproximação para a solução de  $h(x) = 0$  melhor do que  $x_1$ .
- Isso leva ao seguinte processo iterativo:

$$x_m = x_{m-1} - \frac{h(x_{m-1})}{h'(x_{m-1})},$$

no qual  $x_{m-1}$  é uma solução aproximada para  $h(x) = 0$  e  $x_m$  é uma aproximação melhor do que  $x_{m-1}$ .

## Tópico 15: método de Newton-Raphson

- O método de Newton-Raphson consiste em repetir esse processo iterativo até que se obtenha um valor suficientemente próximo da solução de  $h(x) = 0$ .
- Isso ocorre quando algum critério de precisão pré-estabelecido é satisfeito como, por exemplo, quando a distância entre duas aproximações sucessivas se torna menor do que um dado  $\epsilon$ .
- De acordo com esse critério, se  $|x_m - x_{m-1}| < \epsilon$ , então  $x_m$  é suficientemente próximo da solução de  $h(x) = 0$ .
- Nesse caso, toma-se  $x_m$  como sendo a solução dessa equação.
- Conforme já mencionado,  $\hat{\beta}$  é a solução da equação  $\mathbf{U}_{\beta} = 0$ .
- A solução da equação  $\mathbf{U}_{\beta} = 0$  é obtida utilizando-se uma versão multidimensional do método de Newton-Raphson [2, p. 25].



## Tópico 15: método de Newton-Raphson

- Seja  $\beta^{(0)}$  uma solução aproximada para  $\mathbf{U}_\beta = 0$ .
- A aproximação de Taylor de primeira ordem de  $\mathbf{U}_\beta$ , em torno de  $\beta^{(0)}$ , é

$$\mathbf{U}_\beta \approx \mathbf{U}_{\beta^{(0)}} + \mathbf{U}'_{\beta^{(0)}} \left( \beta - \beta^{(0)} \right),$$

onde  $\mathbf{U}'_\beta$  é a matriz  $(p+1) \times (p+1)$ , cujas linhas são as derivadas do vetor  $\mathbf{U}_\beta$  com relação a  $\beta_0, \beta_1, \dots, \beta_p$ .

- Isto é, pelas fórmulas (7) e (17a), tem-se que  $\mathbf{U}'_\beta = -\mathbf{J}_{\beta\beta}$ .
- A aproximação de Taylor de primeira ordem de  $\mathbf{U}_\beta$ , em torno de  $\beta^{(0)}$ , pode, portanto, ser escrita como

$$\mathbf{U}_\beta \approx \mathbf{U}_{\beta^{(0)}} - \mathbf{J}_{\beta^{(0)}\beta^{(0)}} \left( \beta - \beta^{(0)} \right).$$

## Tópico 15: método de Newton-Raphson

- Substituindo  $\mathbf{U}_\beta$ , na equação  $\mathbf{U}_\beta = 0$ , por sua aproximação de Taylor de primeira ordem, obtém-se

$$\begin{aligned}\mathbf{U}_{\beta^{(0)}} - \mathbf{J}_{\beta^{(0)}\beta^{(0)}} \left( \beta - \beta^{(0)} \right) &= 0 \Leftrightarrow \\ \Leftrightarrow \beta &= \beta^{(0)} + \left( \mathbf{J}_{\beta^{(0)}\beta^{(0)}} \right)^{-1} \mathbf{U}_{\beta^{(0)}}.\end{aligned}$$

- Se  $\beta^{(0)}$  é suficientemente próximo da solução de  $\mathbf{U}_\beta = 0$  e se a função  $\mathbf{U}_\beta$  satisfaz certas condições, então

$$\beta = \beta^{(0)} + \left( \mathbf{J}_{\beta^{(0)}\beta^{(0)}} \right)^{-1} \mathbf{U}_{\beta^{(0)}}$$

é uma aproximação da solução de  $\mathbf{U}_\beta = 0$  melhor do que  $\beta^{(0)}$ .

## Tópico 15: método de Newton-Raphson

- Fazendo  $\beta^{(1)} = \beta^{(0)} + \left( J_{\beta^{(0)}\beta^{(0)}} \right)^{-1} \mathbf{U}_{\beta^{(0)}}$ , com base nesse mesmo raciocínio, obtém-se que  $\beta^{(2)}$ , dado por

$$\beta^{(2)} = \beta^{(1)} + \left( J_{\beta^{(1)}\beta^{(1)}} \right)^{-1} \mathbf{U}_{\beta^{(1)}},$$

é uma aproximação da solução de  $\mathbf{U}_{\beta} = 0$  melhor do que  $\beta^{(1)}$ .

- Isso leva ao seguinte procedimento iterativo:

$$\beta^{(m)} = \beta^{(m-1)} + \left( J_{\beta^{(m-1)}\beta^{(m-1)}} \right)^{-1} \mathbf{U}_{\beta^{(m-1)}}, \quad (35)$$

no qual  $\beta^{(m-1)}$  é uma solução aproximada para  $\mathbf{U}_{\beta} = 0$  e  $\beta^{(m)}$  é uma aproximação melhor do que  $\beta^{(m-1)}$ .

## Tópico 15: método de Newton-Raphson

- O método de Newton-Raphson consiste em repetir esse processo iterativo até que se obtenha um valor suficientemente próximo da solução de  $\mathbf{U}_\beta = 0$ .
- Isso ocorre quando algum critério de precisão pré-estabelecido é satisfeito como, por exemplo, quando a distância entre duas aproximações sucessivas se torna menor do que um dado  $\epsilon$ .
- Por esse critério, se  $\|\beta^{(m)} - \beta^{(m-1)}\| < \epsilon$ , então considera-se que  $\beta^{(m)}$  é suficientemente próximo da solução de  $\mathbf{U}_\beta = 0$ .
- Nesse caso, toma-se  $\beta^{(m)}$  como sendo a solução dessa equação.
- Isto é, toma-se tal  $\beta^{(m)}$  como sendo o valor calculado de  $\hat{\beta}$ .
- De posse de  $\hat{\beta}$ , pode-se usar o método de Newton-Raphson para calcular  $\hat{\phi}$ .

## Tópico 15: método de Newton-Raphson

- O método é aplicado para resolver  $U_\phi = 0$ .
- Nesse caso, o processo iterativo, deduzido de forma análoga ao caso unidimensional, fica dado por

$$\phi_m = \phi_{m-1} - \frac{U_{\phi_{m-1}}}{U'_{\phi_{m-1}}} = \phi_{m-1} + \frac{U_{\phi_{m-1}}}{J_{\phi_{m-1}\phi_{m-1}}}, \quad (36)$$

no qual, pelas fórmulas (10) e (17c),  $J_{\phi\phi} = -U'_\phi = -\frac{\partial^2 l}{\partial \phi^2}$ .

- Além disso, em (36),  $\beta$  é substituído por  $\hat{\beta}$ .
- O método de Newton-Raphson consiste em repetir esse processo iterativo até que se obtenha um valor suficientemente próximo da solução de  $U_\phi = 0$ .

## Tópico 15: método de Newton-Raphson

- Isso ocorre quando algum critério de precisão pré-estabelecido é satisfeito como, por exemplo, quando a distância entre duas aproximações sucessivas se torna menor do que um dado  $\epsilon$ .
- De acordo com esse critério, se  $|\phi_m - \phi_{m-1}| < \epsilon$ , então  $\phi_m$  é suficientemente próximo da solução de  $U_\phi = 0$ .
- Nesse caso, toma-se  $\phi_m$  como sendo a solução dessa equação.
- Isto é, toma-se tal  $\phi_m$  como sendo o valor calculado de  $\hat{\phi}$ .

## Tópico 16: método escore de Fisher

- O método escore de Fisher é idêntico ao método de Newton-Raphson, com exceção do fato de que, ao invés de se utilizar a matriz de informação de Fisher observada, usa-se a matriz de informação de Fisher esperada.
- Isto é, na expansão de Taylor de ordem 1 de  $\mathbf{U}_\beta$ , faz-se a substituição de  $\mathbf{J}_{\beta\beta}$  por seu valor esperado  $\mathbf{K}_{\beta\beta}$  em (20a).
- Nesse caso, o procedimento iterativo (35) fica

$$\beta^{(m)} = \beta^{(m-1)} + \left( \mathbf{K}_{\beta^{(m-1)}\beta^{(m-1)}} \right)^{-1} \mathbf{U}_{\beta^{(m-1)}}, \quad (37)$$

- Como o método de Newton-Raphson, o método escore de Fisher repete esse processo iterativo até que se obtenha um valor suficientemente próximo da solução de  $\mathbf{U}_\beta = 0$ .

## Tópico 16: método escore de Fisher

- Analogamente, na expansão de Taylor de ordem 1 de  $U_\phi$ , faz-se a substituição de  $J_{\phi\phi}$  por seu valor esperado  $K_{\phi\phi}$  em (20c).
- Nesse caso, o procedimento iterativo (36) fica

$$\phi_m = \phi_{m-1} - \frac{U_{\phi_{m-1}}}{U'_{\phi_{m-1}}} = \phi_{m-1} + \frac{U_{\phi_{m-1}}}{K_{\phi_{m-1}\phi_{m-1}}}. \quad (38)$$

- Assim como o método de Newton-Raphson, o método escore de Fisher repete esse processo iterativo até que se obtenha um valor suficientemente próximo da solução de  $U_\phi = 0$ .
- Por apresentar diversas vantagens com relação ao método de Newton-Raphson [1, p. 88], recomenda-se, em geral, o uso do método escore de Fisher.



## Tópico 16: método escore de Fisher

- Entretanto, conforme afirma a equação (24c), se a ligação é canônica, então as matrizes  $\mathbf{K}_{\beta\beta}$  e  $\mathbf{J}_{\beta\beta}$  se igualam, igualando os métodos de Newton-Raphson e escore de Fisher, quando aplicados ao parâmetro  $\beta$ .
- O procedimento iterativo (37) pode ser escrito de uma maneira mais conveniente [1, p. 74].
- Note que, a cada passo, o vetor  $\eta$  em (32) e o vetor  $\mu$ , a matriz  $\mathbf{V}$  e a matriz  $\mathbf{W}$  em (12) são atualizados, junto com a atualização de  $\beta$ .
- No passo  $m - 1$ , o vetor de preditores lineares é

$$\begin{aligned}\eta^{(m-1)} &= \left( \eta_1^{(m-1)}, \dots, \eta_n^{(m-1)} \right) = \\ &= \left( \mathbf{x}_1^T \beta^{(m-1)}, \dots, \mathbf{x}_n^T \beta^{(m-1)} \right)^T = \mathbf{X} \beta^{(m-1)}.\end{aligned}$$

## Tópico 16: método escore de Fisher

- O vetor de médias é

$$\boldsymbol{\mu}^{(m-1)} = \left( \mu_1^{(m-1)}, \dots, \mu_n^{(m-1)} \right),$$

$$\text{onde } \mu_i^{(m-1)} = \boldsymbol{g}^{(-1)} \left( \eta_i^{(m-1)} \right) = \boldsymbol{g}^{-1} \left( \boldsymbol{x}_1^T \boldsymbol{\beta}^{(m-1)} \right).$$

- A matriz de funções de variância é

$$\boldsymbol{V}^{(m-1)} = \text{diag} \left\{ V_1^{(m-1)}, \dots, V_n^{(m-1)} \right\},$$

$$\text{onde } V_i^{(m-1)} = V \left( \mu_1^{(m-1)} \right).$$

## Tópico 16: método escore de Fisher

- A matriz de pesos é

$$\mathbf{W}^{(m-1)} = \text{diag} \left\{ \omega_1^{(m-1)}, \dots, \omega_n^{(m-1)} \right\},$$

$$\text{onde } \omega_i^{(m-1)} = \frac{1}{V_i^{(m-1)}} \left. \frac{\partial \mu_i}{\partial \eta_i} \right|_{\eta_i = \eta_i^{(m-1)}}.$$

- Com isso,  $\mathbf{U}_{\beta^{(m-1)}}$  é dado por

$$\mathbf{U}_{\beta^{(m-1)}} = \phi^{-1} \mathbf{X}^T \left[ \mathbf{W}^{(m-1)} \right]^{1/2} \left[ \mathbf{V}^{(m-1)} \right]^{-1/2} \left( \mathbf{Y} - \boldsymbol{\mu}^{(m-1)} \right).$$

- $\mathbf{K}_{\beta^{(m-1)}\beta^{(m-1)}}$  é dado por

$$\mathbf{K}_{\beta^{(m-1)}\beta^{(m-1)}} = \phi^{-1} \mathbf{X}^T \mathbf{W}^{(m-1)} \mathbf{X}.$$

## Tópico 16: método escore de Fisher

- Utilizando essas expressões, pode-se escrever (37) como

$$\beta^{(m)} = \left[ \mathbf{X}^T \mathbf{W}^{(m-1)} \mathbf{X} \right]^{-1} \mathbf{X}^T \mathbf{W}^{(m-1)} \mathbf{z}^{(m-1)}, \quad (39)$$

onde

$$\mathbf{z}^{(m-1)} = \boldsymbol{\eta}^{(m-1)} + \left[ \mathbf{W}^{(m-1)} \right]^{-1/2} \left[ \mathbf{V}^{(m-1)} \right]^{-1/2} \left( \mathbf{Y} - \boldsymbol{\mu}^{(m-1)} \right). \quad (40)$$

- Detalhes sobre a obtenção de (39) podem ser vistos nas notas complementares.
- Nota-se que  $\beta^{(m)}$  é o ajuste de mínimos quadrados ponderados dos coeficientes de uma regressão, na qual  $\mathbf{X}$  representa as preditoras e  $\mathbf{z}^{(m-1)}$  a resposta e  $\mathbf{W}^{(m-1)}$  a matriz de pesos.

## Tópico 16: método escore de Fisher

- Por conta disso, o método escore de Fisher, quando aplicado no cálculo de  $\hat{\beta}$ , é conhecido como procedimento de mínimos quadrados iterativos ponderados [2, p. 25].
- Para iniciar o procedimento iterativo, é necessário fornecer uma estimativa inicial de  $\hat{\beta}$ .
- Ao invés de fornecer uma estimativa inicial para  $\hat{\beta}$ , pode-se fornecer uma estimativa inicial para  $\mu$  é necessária uma estimativa inicial de  $\mu$ .
- Uma escolha comum é considerar o valor observado de  $Y_i$  como estimativa inicial de  $\mu_i$ .
- Nesse caso,  $\mu^{(0)} = \mathbf{y} = (y_1, \dots, y_n)^T$ .
- Com base em  $\mu^{(0)}$ , calcula-se  $\eta^{(0)}$ ,  $\mathbf{V}^{(0)}$ ,  $\mathbf{W}^{(0)}$  e  $\mathbf{z}^{(0)}$ .

## Tópico 16: método escore de Fisher

- Substituindo esses valores em (39), obtém-se

$$\beta^{(1)} = \left[ \mathbf{X}^T \mathbf{W}^{(0)} \mathbf{X} \right]^{-1} \mathbf{X}^T \mathbf{W}^{(0)} \mathbf{z}^{(0)}.$$

- A partir de  $\beta^{(1)}$ , calcula-se  $\eta^{(1)}$ ,  $\mu^{(1)}$ ,  $\mathbf{V}^{(1)}$ ,  $\mathbf{W}^{(1)}$  e  $\mathbf{z}^{(1)}$ .
- Novamente, substituindo esses valores em (39), obtém-se

$$\beta^{(2)} = \left[ \mathbf{X}^T \mathbf{W}^{(1)} \mathbf{X} \right]^{-1} \mathbf{X}^T \mathbf{W}^{(1)} \mathbf{z}^{(1)}.$$

- Repete-se esse processo até que se chegue a um valor  $\beta^{(m)}$  suficientemente preciso.
- Em [1, p. 76], comenta-se sobre possíveis critérios de precisão.
- Em [1, p. 75] e [1, p. 76], encontram-se sugestões sobre como inicializar o método escore de Fisher.

## Tópico 16: método escore de Fisher

- Como aproximação inicial para  $\phi$ , pode-se utilizar o valor do seguinte estimador de Pearson [1, p. 113]

$$\hat{\phi}_P = \frac{1}{n - (p + 1)} \sum_{i=1}^n \frac{(Y_i - \mu_i)^2}{V_i}, \quad (41)$$

onde  $p + 1$  é o número de coeficientes de regressão.

- Na prática, pode-se utilizar o estimador (41) para estimar  $\phi$ , ao invés do estimador de máxima verossimilhança.
- Na plataforma computacional **R**, a função que realiza o ajuste do MLG é a função `glm`.
- A função `gamma.shape`, do pacote **MASS**, calcula a estimativa de máxima verossimilhança de  $\phi^{-1}$ , no caso do modelo gama.

## Tópico 14: estimador de máxima verossimilhança

### Exemplo 9

Considere o conjunto de dados **store.dat**, cuja descrição foi feita no exemplo 2 da aula 2. O objetivo é ajustar um modelo de regressão Poisson, no qual a variável resposta é o número de clientes e as variáveis preditoras são a distância ao concorrente mais próximo e a distância à loja. Os detalhes desse exemplo podem ser vistos no jupyter notebook **exemplo\_9.ipynb** ou no arquivo **exemplo\_9.html**, localizados na pasta das aulas 5 e 6.



## Tópico 14: estimador de máxima verossimilhança

### Exemplo 10

Considere o conjunto de dados **icu.csv**, que se encontra descrito no exemplo 3 da aula 2. O objetivo é ajustar um modelo de regressão logística, tendo a variável **sta** (Sobrevivência) como variável resposta e a variável **age** (Idade) como variável preditora. Os detalhes desse exemplo podem ser vistos no jupyter notebook **exemplo\_10.ipynb** ou no arquivo **exemplo\_10.html**, localizados na pasta das aulas 5 e 6.

## Tópico 14: estimador de máxima verossimilhança

### Exemplo 11

Considere o conjunto de dados **trees.dat**, que se encontra descrito no exemplo 4 da aula 2. O objetivo é ajustar um modelo de regressão gama, com ligação logarítmica, tendo a variável volume como variável resposta e as variáveis altura e diâmetro como variáveis preditoras. Os detalhes desse exemplo podem ser vistos no jupyter notebook **exemplo\_11.ipynb** ou no arquivo **exemplo\_11.html**, ambos na pasta das aulas 5 e 6.

## Referências I

- [1] G. M. Cordeiro e C. G. B. Demétrio, *Modelos lineares generalizados e extensões*, 2013, disponível em <https://docs.ufpr.br/~taconeli/CE22518/LivClarice.pdf>.
- [2] G. A. Paula, *Modelos lineares generalizados com apoio computacional*, 2013, disponível em [https://www.ime.usp.br/~giapaula/texto\\_2013.pdf](https://www.ime.usp.br/~giapaula/texto_2013.pdf).